

הנימוק: קיומה דינוכית:

$$0 \leq z \leq 1, x, y \in S \quad \text{קיומה דינוכית של } S \text{ ו } z \in S$$

$$zx + (1-z)y \in S \quad \text{נקודות:}$$

הנימוק: פולינומית דינוכית:

$$x, y \in S \quad \text{קיים } z \in S \text{ כך ש } f(x) \text{ פולינומית דינוכית ב } S \text{ ו } 0 \leq z \leq 1$$

$$f(zx + (1-z)y) \leq zf(x) + (1-z)f(y)$$

הנימוק: גוף אוניברסלי דינוכית:

A continuously differentiable function $f(x)$ is convex over an interval I if and only if it is above its linear approximation.

$$f(x) \geq f(y) + (x-y)f'(y), \quad \forall x, y \in S.$$

הוכחה:

$$f - \ell \text{ נ.ל.} \Leftarrow$$

$$f(zx + (1-z)y) = f(zx + y - zy) = f(y + z(x-y)) \leq$$

$$\leq zf(x) + (1-z)f(y)$$

לפ. נ.ל. נ.ל.

$$f(y + z(x-y)) \leq zf(x) + (1-z)f(y) \quad / : z$$

$$f(x) \geq \frac{f(y + z(x-y))}{z} - \frac{(1-z)f(y)}{z}$$

$$f(x) \geq \frac{f(y + z(x-y)) - (1-z)f(y)}{z(x-y)} (x-y)$$

$$f(x) \geq \left[\frac{f(y + z(x-y)) - f(y)}{z(x-y)} + \frac{zf(y)}{z(x-y)} \right] (x-y)$$

$$f(x) \geq f'(y)(x-y) + f(y) \blacksquare \quad \downarrow$$

$$f(x) \geq f(y) + (x-y)f'(y)$$

\Rightarrow מינימום נס

כך: רגילה

$$(y-\delta x) \geq z = 2x + (1-2)y$$

Apply the $\Rightarrow f(x) \geq f(z) + (x-z)f'(z) / \cdot (2)$
condition twice

$$f(y) \geq f(z) + (y-z)f'(z) / \cdot (1-2)$$

\rightarrow פונקציית ביצה כפולה של מינימום קירוב.

$$2f(x) + (1-2)f(y) \geq f'(z)$$

הוכחה של מינימום מקומי: גורן

בנוסף למשפט הקיים $f(x)$ מינימום מקומי ב-

$f''(x) \geq 0 \forall x \in S$ ו- x_0 מינימום מקומי

הוכחה:

$\Rightarrow f''(x) \geq 0 \text{ כ נס}$

Using a Taylor expansion:

$$f(y) = f(x) + (y-x)f'(x) + \frac{(y-x)^2}{2}f''(z)$$

Due to $f'' > 0$ we get

$$f(y) \geq f(x) + (y-x)f'(x) \quad \downarrow \text{זהו איבר עדרני.}$$

$$f(y) - f(x) \geq (y-x)f'(x)$$

(לעתה - 'y').

$$f(y) \geq f(x) + (y-x)f'(x)$$

\blacksquare גורן מינימום מקומי ב- x_0 .

$f''(x) < 0$ מינימום נס \Leftarrow

1. מינימום נס כ- x_0 מינימום כ- x_1 ס- x_0

$f''(z) < 0$ כ- x_0 מינימום נס כ- x_2

$$f(y) - f(x) = (y-x)f'(x) + \frac{1}{2}(y-x)^2f''(z) < (y-x)f'(x)$$

\blacksquare גורן מינימום נס

ב) אוניברסיטאות ומכינות נמל הולס, מיל שוכן

נדגער כ, הפונקציית הנמל היא דינמי:

$$\textcircled{1} \quad f(x) = e^x$$

$$\textcircled{3} \quad f(x) = -\log x$$

$$\textcircled{2} \quad f(x) = x^2$$

$$\textcircled{4} \quad f(x) = x \log x$$

טיקנישט אוניברסיטאות ← טיקנישט אוניברסיטאות: גאון

גיאוגרפיה $f(x)$ פירמידה דינמית של S (אוניברסיטאות נייר) ב-
הוּא סטטיסטיק.

חכמת:

ר.ע. א. נייר טיקנישט קב' פירמידה טיקנישט. ①

$f(y) < f(x)$ כי $y < x$ פירמידה טיקנישט. ②

ב- f מינימום ③

$$f(2x + (1-2)y) \leq 2f(x) + (1-2)f(y) <$$

\downarrow $f(x)$ מינימום f

$$\cdot f(2x + (1-2)y) < 2f(x) + (1-2)f(x) = f(x)$$

$f(y) < f(x)$

טיקנישט אוניברסיטאות $x - e$ פירמידה ←

чтобы дойти с $f(x)$ к средней точке, нужно спуститься
когда она \rightarrow . Ступа. ■

Transpose Properties:

$$\textcircled{1} (A^T)^T = A$$

ןעוגפנולן נבצן 2 כ' $AB = BA$ פ.כ. ①

$\text{Tr}(AB) \geq 0$ פ.כ. $A, B > 0$ פ.כ.

$$\textcircled{2} (A+B)^T = A^T + B^T$$

$B > A \geq 0$ פ.כ. ②

$$\textcircled{3} (AB)^T = B^T A^T$$

$B^{-1} < A^{-1}$ פ.כ. נבצן נסובן כ' פ.כ.

$$\textcircled{4} A^T B = B^T A$$

$$\|X\|^2 = X^T X$$

$$\|AX\|^2 = X^T A^T A X$$

Chain Rule:

$$\nabla(X^T Q X) = (Q + Q^T)X = 2QX.$$

$$\textcircled{*} g(x) = f(Ax+b)$$

Jensen's inequality :

F convex :

$$F(\lambda x + (1-\lambda)z, \lambda y + (1-\lambda)w) \leq$$

$$\leq \lambda F(x,y) + (1-\lambda)F(z,w).$$

$$\textcircled{*} g'(x) = A^T \nabla f(Ax+b)$$

$$\bullet F(\lambda x + (1-\lambda)y) \leq \lambda F(x) + (1-\lambda)F(y).$$

$$\textcircled{*} \nabla^2 f(x) > 0 \text{ is equivalent to } b^T f'(x) b \geq 0.$$

$$\textcircled{*}$$

ב' פ.כ. B^{-1} פ.כ. A פ.כ.
ב' פ.כ. AB

$$\textcircled{*} \text{Trace -}$$

ט' פ.כ. פ.כ. פ.כ.

-

ט' פ.כ. פ.כ. פ.כ.

$$\textcircled{*}$$

הכזה כ' פ.כ. פ.כ. פ.כ.

$$\textcircled{*} \text{Cauchy Shwartz : } \sum a_i^2 \sum b_i^2 - (\sum a_i b_i)^2 \geq 0$$

$$\hookrightarrow + a^T b \leq \|a\| \cdot \|b\|$$

הנחות סופירות: דוגמה

$$\alpha x + \beta = \alpha x_1 + \beta + \alpha x_2$$

לעתה נוכיח שקיימת קבוצה C כך שכל היותר אוסף זוגי ב- C מתקבל מההוותה $\alpha x_1 + \beta + \alpha x_2$, כאשר $x_1, x_2 \in C$

$$x_1, x_2 \in C \quad \alpha \in \mathbb{R} \quad \Rightarrow \quad \alpha x_1 + (1-\alpha) x_2 \in C$$

הוכחה של קבוצת כלים סופית: תכונה 8.1.1

$$C = \{x : Ax = b\}$$

הנחות C קבוצה סופית.

הוכחה:

$$Ax_1 = b \quad (1)$$

$$Ax_2 = b \quad (2)$$

$$C \text{ קבוצה סופית } \Rightarrow x_1, x_2 \in C \text{ נקיים } (3)$$

$$\alpha x_1 + (1-\alpha) x_2, \alpha \in \mathbb{R} : \text{הוכחה}$$

נוכיח $\alpha x_1 + (1-\alpha) x_2 \in C$.

$$\Rightarrow A(\alpha x_1 + (1-\alpha) x_2) = \alpha Ax_1 + (1-\alpha) Ax_2 =$$



$$= \alpha b + (1-\alpha)b = b$$

■ $\alpha x_1 + (1-\alpha) x_2 \in C$, הינו קבוצה סופית.

הנחות דוגמאות:

$0 \leq \alpha \leq 1$: נניח $\alpha x_1, x_2 \in C$ מגדיר $\alpha x \in C$ קבוצה C סופית.

$$\alpha x_1 + (1-\alpha) x_2 \in C \quad \text{הוכחה}$$



точка C является из группы.



כג קבוצה אסימטרית או קבוצה קמורה ←

זה לעצם N-2 הגדלתה נקראת ב- Conv_1 .

זה הנקט נ-1 ובעין קמור?

זה עתה קיונתנו גירעון שוכן ב- Conv_1 והוא מוגדר ב- Conv_1 כי אם $x, y \in \text{Conv}_1$ אז $\lambda x + (1-\lambda)y \in \text{Conv}_1$.

ספונטניות דינמי:

1) HyperPlane: $\{x : a^T x = b\}$, $a \neq 0$ is affine & convex.

תיכו:

נניח $x, y \in \text{Conv}_1$ הינה:

$$a^T x = b$$

$$a^T y = b$$

לפי נ-2 הדרישה דינמיות גירעון:

$$\lambda x + (1-\lambda)y$$

ריבן של (הונקייה) גורק פונקציית:

$$\begin{aligned} a^T(\lambda x + (1-\lambda)y) &= \lambda a^T x + (1-\lambda)a^T y = \\ &= \lambda b + (1-\lambda)b = b. \end{aligned}$$

זה מוכיח רדי אידמיות קמורה, מכאן שפונטניות דינמיות.

2) Halfspace: $\{x : a^T x \leq b\}$, $a \neq 0$ is convex
but not affine

$$\begin{aligned} a^T x \leq b \\ a^T y \leq b \end{aligned} \rightarrow a^T(\lambda x + (1-\lambda)y) = \lambda a^T x + (1-\lambda)a^T y \leq$$

$$\lambda b + (1-\lambda)b = b. \quad \blacksquare$$

ריבן של (הונקייה) גורק פונקציית:



- Euclidean ball $\{x : \|x - c\|_2 \leq r\}$, $r > 0$ is convex.

לרכ. ע:

① ניקח 2 נקודות x_1, x_2 ויראינו קונכיזה גיאומטרית.

בנין 2 על הקונכיזה ג'תוק הינה וקצת


$$\|2x_1 + (1-2)x_2 - c\| = \|2x_1 + x_2 - 2x_2 - c + 2c - 2c\| = \\ \downarrow \\ 2c \text{ ויראינו}$$

$$= \|2(x_1 - c) + (1-2)(x_2 - c)\|_2 \leq \underbrace{2\|x_1 - c\|}_\text{edge} + (1-2)\|x_2 - c\|_2 \leq$$

$$\leq 2r + (1-2)r = r \blacksquare$$

- Second order (ice-cream, Lorentz, quadratic) cone:

$\{(x, t) : \|x\|_2 < t\}$ is convex



Similar way to write: $\|x\|_2 - t \leq 0$

① ניקח 2 נקודות x_1, x_2 ויראינו קונכיזה גיאומטרית.

$\|x_1\|_2 \leq t_1, \|x_2\|_2 \leq t_2$. ויראינו קונכיזה גיאומטרית.

② ניקח 2 נקודות x_1, x_2 ויראינו קונכיזה גיאומטרית.

ויראינו קונכיזה גיאומטרית.

$$\|2x_1 + (1-2)x_2\|_2 - 2t_1 - (1-2)t_2 \leq \\ \downarrow \\ \text{edge sum inc}$$

$$\leq 2\|x_1\|_2 + (1-2)\|x_2\|_2 - 2t_1 - (1-2)t_2 =$$

$$= 2 \underbrace{\left(\|x_1\|_2 - t_1\right)}_{\leq 0} + (1-2) \underbrace{\left(\|x_2\|_2 - t_2\right)}_{\leq 0} \leq 0$$



• Positive semidefinite cone is convex.

$$S_+^n = \{ X \in S^n : X \geq 0 \} =$$

$$= \{ X \in S^n : Z^\top X Z \geq 0, \forall Z \}$$

ליכע:

רנו $x_1, x_2 \in S_+^n$ כוונת'ו: ①

$$Z^\top x_1 Z \geq 0$$

$$Z^\top x_2 Z \geq 0$$

רכינ' קונכיז'ה גיאומט' ②

$$2x_1 + (1-2)x_2$$

רכינ' קונכיז'ה ומכפ' ③

$$Z^\top (2x_1 + (1-2)x_2) Z = 2Z^\top x_1 Z + (1-2)Z^\top x_2 Z \geq 0$$

אקספליקט של אוניברסיטאות

הוכחה ①

$S_1 \cap S_2$ הוא אוניברסיטאות אם ורק אם $S_2 \cap S_1$ הוא אוניברסיטאות.

הוכחה:

$$x \in S_1 \cap S_2 \rightarrow x \in S_1 \text{ ו } x \in S_2 \quad ①$$

$$y \in S_1 \cap S_2 \rightarrow y \in S_1 \text{ ו } y \in S_2 \quad ②$$

$\therefore y \in S_1 \cap S_2 \rightarrow x \in S_1 \text{ ו } y \in S_2 \quad ③$

$$2x + (1-2)y \in S_1 \quad ④$$

$2x + (1-2)y \in S_2$

$\therefore 2x + (1-2)y \in S_1 \text{ ו } 2x + (1-2)y \in S_2$ ■

הוכחה ②

$\bigcap_{z \in A} S_2$ הוא אוניברסיטאות אם ורק אם A הוא אוניברסיטאות.

Важно обратить внимание, что A не однозначно convex.

Example: the positive semidefinite cone can be expressed as the intersection of an infinite number of halfspaces and is therefore convex:

$$\{X \in S^n : X \geq 0\} = \bigcap_{z \neq 0} \{X \in S^n : z^T X z \geq 0\}. \quad \downarrow$$

כג ③

ו $S_1 \times S_2$ פ"כ מ"כ קיימת גורם 2 ב $S_2 \cup S_1$ פ"כ

$$S_1 \times S_2 = \{ X_1, X_2 : \begin{array}{l} X_1 \in S_1 \\ X_2 \in S_2 \end{array} \}$$

הוכחה

$$X = (X_1, X_2), X \in S_1 \times S_2 \quad ①$$

$$Y = (Y_1, Y_2), Y \in S_1 \times S_2 \quad ②$$

$$\lambda \in (0, 1) \quad ③$$

$$\forall i=1,2 \text{ מ"ג } X_i, Y_i \in S_i \quad ④$$

$$\therefore \exists \lambda \in (0, 1) \text{ מ"ג } S_2 \cup S_1 \quad ⑤$$

$$\lambda X_1 + (1-\lambda) Y_1 \in S_1$$

$$\lambda X_2 + (1-\lambda) Y_2 \in S_2$$

: p81 ⑥

$$(\lambda X_1 + (1-\lambda) Y_1, \lambda X_2 + (1-\lambda) Y_2) \in S_1 \times S_2$$

: מ"כ גורם 1 כ

$$\lambda (X_1, Y_1) + (1-\lambda) (Y_1, Y_2) \in S_1 \times S_2$$

הוכחה 4 אוניברזי סטטוס ④

ו $f(x)$ פ"כ גורם גוף הטריזיה תומך ב S פ"כ


$$f(x) = Ax + b \quad \text{: מ"ג } f(x) \text{ כפ"כ}$$

$$f(S) = \{ Ax + b : x \in S \} \quad \text{: מ"ג } f(S) \text{ כפ"כ}$$

הוכחה

$$f_1 \in f(S), f_1 = Ax_1 + b \quad \text{: מ"כ } x_1 \in S \text{ ו"נ}$$

$$f_2 \in f(S), f_2 = Ax_2 + b \quad \text{: מ"כ } x_2 \in S \text{ ו"נ}$$



הוכיח ביחס למינימום אונטראיאלי

$$f' = 2f_1 + (1-2)f_2 \in f(S).$$

$$x' = 2x_1 + (1-2)x_2$$

$$Ax' = f' - b$$

ולכן אונטראיאלי

$$\Rightarrow A(2x_1 + (1-2)x_2) = 2Ax_1 + (1-2)Ax_2 =$$

$$= 2(f_1 - b) + (1-2)(f_2 - b) =$$

$$= 2f_1 + f_2 - 2f_2 - b =$$

$$= 2f_1 + f_2(1-2) - b = f' - b. \blacksquare$$

5 חישוב הופכי ואוסף הכהה אם פונקציית כפלים:

$f(x) = Ax + b$ כדי להוכיח שההופכי של הוסף הכהה S הוא כפlica דהויה.

$$f(x) = Ax + b : f(x) \text{ מושג פה!} -$$

$$f^{-1}(S) = \{x : Ax + b \in S\} : \text{ וההנורח ההופכי}$$

הוכחה

$$x_1 \in f^{-1}(S) : Ax_1 + b \in S \quad ①$$

$$x_2 \in f^{-1}(S) : Ax_2 + b \in S \quad ②$$

$$x_2, x_1 \text{ ו } 2- \text{ בז' } \rightarrow \text{ נרער קומבינציית פיראכין} \quad ③$$

$$2x_1 + (1-2)x_2$$

$$f \in f^{-1}(S) \text{ מפני } Ax + b \in S \quad \text{לע"מ } 2x_1 + (1-2)x_2 \in S \quad ④$$

$$Ax + b = 2(Ax_1 + b) + (1-2)(Ax_2 + b) \in S^{\text{convex}} \blacksquare$$

בז' פיראכין
db.



הוכחה נסיעה ⑥

אנו מוכיחים כי βS הוא קבוצה סגורה ב- S אם ורק אם S סגורה ב- \mathbb{R} .

$$\beta S = \{ \beta x : x \in S \}$$

אנו נוכיח כי βS סגורה.

הוכחה:

אם $\beta S = \{0\}$ אז $\beta = 0$ ו- S סגורה.

אם $\beta \neq 0$ אז S סגורה.

$x, y \in S$: $x \neq y$ ו- $\beta x \neq \beta y$

$$\frac{x}{\beta} \in S, \frac{y}{\beta} \in S$$

רתקות נסיעה $S - e$ מגדלת.

$$2 \cdot \frac{x}{\beta} + (1-2) \frac{y}{\beta} \in S$$

: $\beta \rightarrow 0$ מגדלת.

$$2x + (1-2)y \in \beta S$$

■ βS סגורה.

הוכחה נסיעה ⑦

אנו מוכיחים כי $S + \beta$ סגורה אם ורק אם S סגורה.

$$S + \beta = \{ x + \beta : x \in S \}$$

הוכחה נסיעות דינמיות ⑧

: אנו נוכיח $S_1 + S_2$ סגורה.

$$S_1 + S_2 = \{ x_1 + x_2 : x_1 \in S_1, x_2 \in S_2 \}$$

הוכחה:

$$x, y \in S_1 + S_2 \quad (1)$$

$$x_2 \in S_2 \quad x_1 \in S_1, \quad x = x_1 + x_2 \quad (2)$$

$$y_2 \in S_2 \quad y_1 \in S_1, \quad y = y_1 + y_2 \quad (3)$$

$$x_1 \in S_1 \quad y_1 \in S_1 \quad (4)$$

$$2x_1 + (1-2)y_1 \in S_1$$

$$2x_2 + (1-2)y_2 \in S_2$$



$$\begin{aligned}
 & \Rightarrow dX_1 + (1-2)y_1 + 2X_2 + (1-2)y_2 = \\
 & = 2X_1 + y_1 - 2y_1 + 2X_2 + y_2 - 2y_2 = \\
 & = 2(X_1 + X_2) + (1-2)(y_1 + y_2) \in S_1 + S_2. \blacksquare
 \end{aligned}$$

הוכחה של קבוצת כל ה-3 נורמלים: KNC13

Ellipsoid: $\{x: (\underline{x} - \underline{c})^T P^{-1} (\underline{x} - \underline{c}) \leq 1\}$

הוכחה של קבוצת כל ה-3 נורמלים: KNC13

$$P = U^T U^{-1}$$

$$P^{-1} = U^T U$$

$$\{x: (\underline{x} - \underline{c})^T \underbrace{U^T}_{A^T} \underbrace{U}_{A} (\underline{x} - \underline{c}) \leq 1\} = A^T B = B^T A$$

$$= \{x: \|Ux - UC\|_2^2 \leq 1\} =$$

$$= \{x: Ux - UC \in \underbrace{\{z: \|z\| = 1\}}_{\text{סfer}}$$

■ הוכחה של KNC13

Формула:

$$\textcircled{1} \quad \|AX\|_2^2 = x^T A^T A x$$

$$\textcircled{2} \quad (A+B)^2 = A^2 + AB + BA + B^2$$



: גאון

דנוביה דנוביה ארכטורה זא דל

דנוביה הייע דנוביה זא מ' חינוק דנוביה זא כ' יאל הייע דנוביה

תמכה:

לפיו כי הנקודות דנוביה \Leftarrow

שווים יאנז אוניבוק הון א דנוביה דנוביה זא דנוביה
נבד נבד אוניבוק דנוביה זא יאל עלי זא דנוביה

לפיו אוניבוק דן זא דנוביה הייע דנוביה \Rightarrow
 $x_1, x_2 \in S$ ז אוניבול

חינוק זא יאל הזאה נון א הנקודות הייע דנוביה (הוועז).
 $2x_1 + (1-2)x_2 \in S \cap \text{Line}$

↓

$2x_1 + (1-2)x_2 \in S$

↓

S דנוביה ■

לונק קון לינז זא דנוביה : גאון

Prove that the solution set of a quadratic
inequality C, is convex if $A \geq 0$.

$$C = \{x: x^T A x + x^T b + c \leq 0\}$$

יאר טב יאל ①

לונק אוניבוק ②

וונל אוניבוק נעל עלי דנוביה זא דנוביה ③

הוכחה:

① Choose an arbitrary line:
 $\{x + tv \mid t \in \mathbb{R}\}$

② נציג ערך אמצעי 2 על ידי נקודות על ישר

$$(x + tv)^T A(x + tv) + (x + tv)^T b + c$$

③ We express ② as:

$$\lambda^2 t^2 + \beta t + \gamma \leq 0$$

④ Where:

$$\lambda = v^T A v$$

$$\beta = b^T v + 2x^T A v$$

$$\gamma = c + b^T x + x^T A x$$

⑤ Explanation:

$$\cdot (x + tv)^T = x^T + (tv)^T = x^T + v^T t^T$$

$$\square: (x^T + v^T t^T)^T A (x + tv) = \underline{x^T A x} + \underline{x^T A t v} + \underline{v^T t^T A x} + \underline{v^T t^T A t v}$$

$v^T A v$: מינימום קומטני של t^2 הוא 0

$2x^T A v$: מינימום של t^2 הוא 0

$$\hookrightarrow (x + tv)^T b = b^T (x + tv) = \underline{b^T x} + \underline{b^T t v}$$

t הוא מינימום של t^2 → 0

$b^T x$ הוא מינימום של $b^T x$ → 0



⑥ Thus, the intersection is defined as:

$$\{x + tv \mid \alpha t^2 + \beta t + \gamma \leq 0\}$$

$$\alpha \geq 0 \text{ and } \Delta \leq 0$$

intersection set along the curve

$$V^T A V \geq 0 \quad \forall V$$

הוכחה של דבוקה של פונקציית פרפקטיבית:-open

$$p(x) = \frac{x_1:n}{x_{n+1}}$$

הוכחה של פונקציית פרפקטיבית:

דבוקה

The image of convex set under its perspective function is convex.

טענה: $p(S) = \{p(x) : x \in S\}$ הוא קבוצה כפולה (convex) (because $x \in S \Rightarrow \mu x + (1-\mu)x' \in S$)

הוכחה:

$$p_1 = p(x) \quad \text{זה אומר } x \in S \text{ ו } p_1 \in p(S) \quad ①$$

$$p_2 = p(y) \quad \text{זה אומר } y \in S \text{ ו } p_2 \in p(S) \quad ②$$

$$0 \leq \mu \leq 1 \quad \text{זה אומר } \mu \text{ בינהו}$$

$$\mu p_1 + (1-\mu)p_2 \in p(S)$$

$$\text{זה אומר } z \in S \text{ בינהו}$$

$$\mu p_1 + (1-\mu)p_2 = p(z)$$

$$z \in \text{ההיפרפלה } \Theta X + (1-\Theta)Y \text{ בינהו}$$

$$z = \Theta x + (1-\Theta)y$$

$$\text{זה אומר } \mu \text{ בינהו}$$

$$\Rightarrow \Theta = \frac{\mu y_{n+1}}{\mu y_{n+1} + (1-\mu)x_{n+1}} \quad ; \quad \mu = \frac{\Theta x_{n+1}}{\Theta x_{n+1} + (1-\Theta)y_{n+1}} =$$

$$= \frac{\mu}{x_{n+1}} = \frac{\Theta}{\Theta x_{n+1} + (1-\Theta)y_{n+1}}$$

בדוקה לכך x_{n+1}

$$\Rightarrow p(z) = p(\Theta x + (1-\Theta)y) = \frac{\Theta x_{1:n} + (1-\Theta)y_{1:n}}{\Theta x_{n+1} + (1-\Theta)y_{n+1}} =$$



$$= \frac{\theta x_{1:n} + (1-\theta)y_{1:n}}{\theta x_{n+1} + (1-\theta)y_{n+1}} =$$

↓

$$\frac{\theta}{\theta x_{n+1} + (1-\theta)y_{n+1}} = \frac{\mu}{x_{n+1}} \quad \frac{1-\theta}{\theta x_{n+1} + (1-\theta)y_{n+1}} = \frac{1-\mu}{y_{n+1}}$$

$$= \frac{\mu \cdot x_{1:n}}{x_{n+1}} + \frac{(1-\mu) y_{1:n}}{y_{n+1}} = \mu p(x) + (1-\mu) p(y) =$$

$$= \mu p_1 + (1-\mu) p_2 \blacksquare$$

הכרה: פונקציה קמורה

אם דיניא $x \in D$ ו $0 \leq t \leq 1$ ו $y \in X$ אז $f(tx + (1-t)y) \leq tf(x) + (1-t)f(y)$

: מוגדר אם

$$f(tx + (1-t)y) \leq tf(x) + (1-t)f(y)$$

אזי f דינומית.

Օրևուն x և y վեկտորն և ապահովագույն:

DEFINITION: פונקցיה דינומית ու էվկլիումիական գործ

էվկლիումիական f կողմէն էման իւն դինում շարժ առնելու մեջ ըստ գործի առաջնային գործականության:

→ A function is convex if and only if it is convex when restricted to any line that intersects its domain.

$$x \text{-ա արևունք } f(x) \Leftrightarrow g(t) = f(tx + (1-t)x) \text{ առաջնային գործ}$$

ՀԱՅՐԱԿԱՆ

$$f(tx + (1-t)x) = g(t) = f(x + t(y-x)) \quad \text{թերզ էլուս է դինում} \quad ①$$

↓ առաջնային գործ f էվկլիումիական էլուս \Rightarrow ②

$$g\left(\underbrace{\theta t + (1-\theta)\bar{t}}_t\right) = f\left(x + \underbrace{(\theta t + (1-\theta)\bar{t})(y-x)}_t\right) =$$

$$= f(x + (y-x)(\theta t + (1-\theta)\bar{t})) = f(x + y\theta t + y(1-\theta)\bar{t} - x\theta t - x(1-\theta)\bar{t}) =$$

թարգմանություն և առաջնային գործ

$$= f(x + \theta(yt - xt) + (1-\theta)(y\bar{t} - x\bar{t})) =$$

θ 103y ↓

(1-θ)1

$$= f(x + \cancel{\theta x} + \theta t(y-x) + (1-\theta)\bar{t}(y-x) - \cancel{\theta x}) =$$

թարգմանություն և առաջնային գործ

θx, -θx

$$= f(\theta(x + t(y-x)) + (1-\theta)(x + \bar{t}(y-x))) \quad \downarrow \leq$$

$$\text{Convexity} \quad \leq \quad \underbrace{\theta f(x + t(y-x))}_{g(t)} + (1-\theta) \underbrace{f(x + \bar{t}(y-x))}_{g(\bar{t})}$$

. yix δg t - g(x) ⇐ ③

$$g(\theta) \leq \theta g(1) + (1-\theta)g(0)$$

||

$$f(x + t(y-x)) \leq \theta f(y) + (1-\theta)f(x) \blacksquare$$

הוכחה: דמיון אוניברסלי

האך נוכיח כי כל פונקציה יר谨ה היא יר谨ה כפולה של הפונקציה היר谨ה שבליה:

$$f(y) \geq f(x) + \nabla f(x)^T (y-x)$$

הוכחה:

① Let's restrict to a line

$$g(t) = f(ty + (1-t)x)$$

② Deriv:

$$g'(t) = \nabla f(ty + (1-t)x)^T (y-x)$$

t=0 מינימום g(t) בx=t=0 מינימום f(x) ⇐ ③ ⇐

$$g(1) \geq g(0) + (1-0)g'(0) \quad t=0, y=1.$$

Which is exactly what we need to prove.

מינו כי f יר谨ה פונקציה שבליה ④ ⇒

בנוסף לכך:

$$\begin{aligned} y \in g & \quad y = ty + (1-t)x \\ x \in g & \quad x = \bar{t}y + (1-\bar{t})x \end{aligned} \quad \downarrow$$

to obtain:

$$f(ty + (1-t)x) \geq f(\bar{t}y + (1-\bar{t})x) + \nabla f(\bar{t}y + (1-\bar{t})x)^T (ty + (1-t)x - \bar{t}y - (1-\bar{t})x)$$

$$f(ty + (1-t)x) \geq f(\bar{t}y + (1-\bar{t})x) + \nabla f(\bar{t}y + (1-\bar{t})x)^T (y-x)(t-\bar{t}).$$

which means: $g(t) \geq g(\bar{t}) + g'(\bar{t})(t-\bar{t})$

and therefore $g(t)$ is convex and so is $f(x)$. ■

:הנימוק של פונקציית גודן

פונקציה קיימת נגזרת כפולה $\nabla^2 f(x) > 0$ אז מינימום $f(x)$

הוכחה:

$$g(t) = f(a + tb) \quad \text{רבייה ב-1} \quad ①$$

$$g'(t) = b^T \nabla f(tb + a) \quad : \text{לכזנה}$$

$$g''(t) = b^T \nabla^2 f(tb + a) b \geq 0$$

which is equivalent to $\nabla^2 f(x) > 0$. ■



דָּבָר נִזְמָנָה גֶּאֱלָקְצִיּוֹן דַּיְנוּכִים:

: גָּזֵן

הוכחה: $f(x)$ דנילס, כי S דנילס, כי $f(x) \leq 0$
 $S = \{x : f(x) \leq 0\}$

הוכחה:

$f(y) \leq 0, f(x) \leq 0 \Rightarrow x, y \in S$ ①

כדי גהוכו $\forall x, y \in S$ דנילס, כי f גראף פירטלי
ה�ק f דנילס.

$$f(2x + (1-2)y) \leq 2f(x) + (1-2)f(y) \leq 0$$

↓

f

דנילס

: epigraph , הוגה : גראף

The epigraph is the set above the function
i.e. $\{[x, t] : f(x) > t\}$

: גָּזֵן נִיכְרָת

דָּבָר נִזְמָנָה גֶּאֱלָקְצִיּוֹן

A function $f(x)$ is convex in x iff its epigraph
 $\{[x, t] : f(x) \leq t\}$ is convex in $[x, t]$.

הוכחה:

\Leftrightarrow כילו t ו u כי $f(x) \leq t$ דנילס

$\Rightarrow f(x) - t$ דנילס

$f(x) - t \leq 0$ דנילס



כליה: מינימום פונקציית f ⇒

$$\left\{ \begin{bmatrix} \hat{x} \\ t \end{bmatrix} : f(x) \leq t \right\} - \text{convex}$$

① Consider x_1 and x_2 and let :

$$t_1 = f(x_1)$$

$$t_2 = f(x_2)$$

② Then : $(x_1, t_1) \in \text{epif}$
 $(x_2, t_2) \in \text{epif}$

③ So : $\lambda x_1 + (1-\lambda)x_2 \in \text{epif} \rightarrow$ מינימום פונקציית
 $\lambda t_1 + (1-\lambda)t_2 \in \text{epif} \rightarrow$ פונקציית

④ And : $f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda t_1 + (1-\lambda)t_2 =$
פונקציית epi מינימום ↪
 $= \lambda f(x_1) + (1-\lambda)f(x_2).$

הוכחה: גדרת פונקציית מינימום

Norms: (מינימום)

כגון $\|x\|$ הינו פונקציה מינימום

הוכחה:

$$\|2x + (1-2)y\| \leq \|2x\| + \|(1-2)y\| = 2\|x\| + (1-2)\|y\| \blacksquare$$

down ↓
between x and y

Max: (מינימום מינימום)

$f(x) = \max\{x_1, \dots, x_n\}$ פונקציית מינימום מינימום $f(x)$

הוכחה:

$$\max\{2x_i + (1-2)y_i\} \leq \max_i\{2x_i\} + \max_i\{(1-2)y_i\} =$$

$$= 2\max_i\{x_i\} + (1-2)\max_i\{y_i\} \blacksquare$$



Quadratic-over-linear (\min_{def} ac)

$f(x,y) = \frac{x^2}{y}$ is convex on $\{(x,y) : y > 0\}$

$$\nabla f = \begin{bmatrix} \frac{2x}{y} \\ -\frac{x^2}{y^2} \end{bmatrix}$$

היכלה:
Не зайдите выше бикомп!

$$\nabla^2 f = \begin{bmatrix} \frac{2}{y} & -\frac{2x}{y^2} \\ -\frac{2x}{y^2} & \frac{2x^2}{y^3} \end{bmatrix} = \frac{2}{y^3} \cdot \begin{bmatrix} y^2 & -xy \\ -xy & x^2 \end{bmatrix} =$$

no x no y

$$= \frac{2}{y^3} \cdot \begin{bmatrix} y \\ -x \end{bmatrix} [y - x] \geq 0$$

если
можно найти корень.

: epi גבורה היכלה

$$\{x, y, t : \frac{x^2}{y} \leq t, y \geq 0\}$$

⇓

$$\{x, y, t : \begin{bmatrix} y & x \\ x & t \end{bmatrix} \geq 0\} \quad yt \geq x^2$$

↳ determinanta.

\min_{def} to positive definite גיבובן גדרה כ ערך

מבחן פסוי

Log Sum Exp:

הפונקציה $f(x)$ הינה סכום של מעריכיות e^{x_i} ו- \log מינימום:

$$f(x) = \log \sum_{i=1}^n e^{x_i}$$

הוכחה:

לפיו $\nabla f(x) = \frac{\partial f}{\partial x_i} = \frac{e^{x_i}}{\sum e^{x_i}}$

$$\rightarrow \nabla f(x) = \frac{\begin{bmatrix} e^{x_1} \\ \vdots \\ e^{x_n} \end{bmatrix}}{\sum e^{x_i}} = \frac{\underline{z}}{1^T z}$$

$e^{x_i} = z_i$

$$\begin{aligned} \rightarrow \nabla^2 f(x) &= \left[\frac{I}{1^T z} - \frac{z \cdot 1^T}{(1^T z)^2} \right] \underbrace{\begin{bmatrix} e^{x_1} & 0 \\ 0 & \ddots \\ 0 & 0 \end{bmatrix}}_{\text{בניטרלי מטריצת}} = \\ &\quad \downarrow \\ &\quad (\frac{u}{v})' = \frac{u'}{v} - \frac{v'u}{v^2} \\ &= \text{diag}(z) \\ &= \left[\frac{I}{1^T z} - \frac{z 1^T}{(1^T z)^2} \right] \cdot \text{diag}(z) \end{aligned}$$

$u^T \nabla^2 f(x) u \geq 0$ נוסף לכך
 $\nabla^2 f(x) \geq 0 \Leftrightarrow$ ממשה נורמלית

$$\begin{aligned} \rightarrow u^T \nabla^2 f(x) u &= \frac{u^T \text{diag}(z) u}{1^T z} - \frac{u^T z 1^T \text{diag}(z) u}{(1^T z)^2} = \\ &= \frac{\sum u_i^2 z_i}{\sum z_i} - \frac{(\sum u_i z_i)^2}{(\sum z_i)^2} = \\ &= \frac{1}{(\sum z_i)^2} \cdot \left[\sum z_i \cdot \sum u_i^2 z_i - (\sum u_i z_i)^2 \right] \geq 0 \end{aligned}$$



הנורמליזציה

Cauchy-Schwartz:

$$\sum a_i^2 \sum b_i^2 - (\sum a_i b_i)^2 \geq 0$$

$$a_i = \sqrt{z_i} u_i \quad \text{הנורמליזציה}$$

$$b_i = \sqrt{z_i} u_i$$

-Logdet(X):

$$\text{הנורמליזציה של } f(x) \text{ היא } f(x) = -\log \det(x)$$

- We will find the gradient matrix
of logdet(x) by completing:

$$f(x+D) = f(x) + \text{Tr}\{D \nabla f\}$$

$$X = X^{\frac{1}{2}} X^{\frac{1}{2}} \quad \text{הנורמליזציה של } \lambda_i \\ X^{\frac{1}{2}} = U D^{\frac{1}{2}} U^T$$

$$\Rightarrow \log |x+D| = \log |x| + \log |I + X^{-\frac{1}{2}} D X^{-\frac{1}{2}}| =$$

$$= \log |x| + \sum_i \log \lambda_i (I + X^{-\frac{1}{2}} D X^{-\frac{1}{2}}) =$$

$$= \log |x| + \sum_i \log (1 + \lambda_i (X^{-\frac{1}{2}} D X^{-\frac{1}{2}})) =$$

$$\log(1+\varepsilon) = \varepsilon \quad \Leftrightarrow \quad \log |x| + \sum_i \lambda_i (X^{-\frac{1}{2}} D X^{-\frac{1}{2}}) =$$

$$\sum \lambda_i = \text{Tr} \quad \Leftrightarrow \quad \log |x| + \text{Tr}(X^{-\frac{1}{2}} D X^{-\frac{1}{2}}) = \log |x| + \text{Tr}(\underline{X^{-1} D})$$

$$\nabla f = X^{-1}$$

Convexity proof of the function:

Restrict to a line: $X = Z + tV$

where: Z and V are symmetric.

Not necessarily positive definite.

We look for t 's for which $Z + tV > 0$.

We assume $Z > 0$, i.e. $t=0$ is in the domain.

$$\Rightarrow g(t) = \log |Z + tV| =$$

$$= \log |Z^{\frac{1}{2}} (I + tZ^{-\frac{1}{2}} V Z^{-\frac{1}{2}}) Z^{\frac{1}{2}}| =$$

$$= \log |I + tZ^{-\frac{1}{2}} V Z^{-\frac{1}{2}}| + \log |Z| =$$

Внесли λ_i и получили
 $\sum_{i=1}^n \lambda_i = I$

$$\Rightarrow \sum_i \log (1 + t\lambda_i) + \log |Z|$$

$$\Rightarrow g'(t) = \sum_i \frac{\lambda_i}{1 + t\lambda_i}$$

$$g''(t) = - \sum_i \frac{\lambda_i^2}{(1 + t\lambda_i)^2} \leq 0$$



: גורם דינמי של מינימיזציה מינימום

- Non negative weighted sums :

$$\text{לינר } \sum_{i=1}^n w_i f_i \quad \text{אך } \sum_{i=1}^n f_i \leq 1$$

\downarrow
sum

- Composition with affine mapping:

$$g(x) = f(Ax + b) \quad \text{לינר } g(x) \quad \text{אך } \sum_{i=1}^n f_i \leq 1$$

: גורם

$$g(\theta x + (1-\theta)y) = f(A(\theta x + (1-\theta)y) + b) =$$

\downarrow
הנץ

$$= f(\theta(Ax + b) + (1-\theta)(Ay + b)) \leq$$

\downarrow
הנץ

$$\leq \theta f(Ax + b) + (1-\theta)f(Ay + b) \leq$$

$$\leq \theta g(x) + (1-\theta)g(y) \blacksquare$$

- Pointwise maximum and supremum

$$\text{אך } \max_{x \in X} f_1(x) \text{ ו } f_2(x) \leq f(x) = \max\{f_1(x), f_2(x)\}$$

($\max_{x \in X} f_1(x) \leq f(x) \leq \max_{x \in X} f_2(x)$) $\forall x \in X$

- $g(x) = \max_y f(x, y)$ is convex

$x_2 \geq x_1 \Rightarrow f(x_2, y) \geq f(x_1, y) \quad \text{ריבועי } ①$

$$g(x_1) = \max_y f(x_1, y)$$

$$g(x_2) = \max_y f(x_2, y)$$



② $\max f(x_1, y) \leq g(x_1)$

$$2x_1 + (1-2)x_2$$

$\cdot g - \delta \in \mathcal{G}$

$$g(2x_1 + (1-2)x_2) = \max_y f(2x_1 + (1-2)x_2, y) \leq$$

הנחה

$$\leq \max_{y_1, y_2} f(2x_1 + (1-2)x_2, 2y_1 + (1-2)y_2) \leq$$

$y \in \mathcal{G}$ הינה

הנחתה

f דינמי

ו- y_1, y_2 דינמיים

y ו- y_1, y_2 דינמיים

$2y_1 + (1-2)y_2$

Jensen

$$\leq \max_{y_1} f(x_1, y_1) + (1-2) \max_{y_2} f(x_2, y_2) =$$

$$= 2g(x_1) + (1-2)g(x_2) \blacksquare$$

הנחתה יתבצע בדינמיות

$$\cdot g(x) = \min_y f(x, y)$$

$y = x$ יתבצע בדינמיות

$g(x)$ דינמי

x_2, x_1 יתבצעו בדינמיות ①

$$g(x_1) = f(x_1, y_1)$$

$$g(x_2) = f(x_2, y_2)$$

$$g(2x_1 + (1-2)x_2) = \min_y f(2x_1 + (1-2)x_2, y) \leq \downarrow \text{הנחתה } y \in \mathcal{G}$$

$$\leq \min_{y_1, y_2} f(2x_1 + (1-2)x_2, 2y_1 + (1-2)y_2) \leq \downarrow \text{Jensen's extention}$$

$$\leq 2\min f(x_1, y_1) + (1-2)\min f(x_2, y_2) = 2g(x_1) + (1-2)g(x_2)$$



Schur's lemma:

Let $C > 0$, then $X = \begin{bmatrix} A & B \\ B^T & C \end{bmatrix} \geq 0$ if and only if

$$S = A - BC^{-1}B^T \geq 0 \Rightarrow \begin{bmatrix} AC - BBT \geq 0 \text{ (det)} \\ A - BC^{-1}B^T \geq 0 \\ \text{gemepmuuama} \geq 0 \end{bmatrix}$$

: 2020

① A matrix X is positive semidefinite if and only if XTX^T is positive semidefinite for an invertible matrix T .

② If C is invertible then we have the following block Cholesky decomposition:

$$X = \begin{bmatrix} A & B \\ B^T & C \end{bmatrix} = \begin{bmatrix} I & BC^{-1} \\ 0 & I \end{bmatrix} \begin{bmatrix} S & 0 \\ 0 & C \end{bmatrix} \begin{bmatrix} I & BC^{-1} \\ 0 & I \end{bmatrix}^T$$

③ The matrix $\begin{bmatrix} I & BC^{-1} \\ 0 & I \end{bmatrix}$ is invertible. And a block diagonal matrix is positive semidefinite if and only if its blocks are positive semidefinite.

④ Thus, when $C > 0$, $X \geq 0$ if and only if $S \geq 0$.

⑤ This is a generalization of Cauchy-Schwarts since:

$$\begin{bmatrix} A & B \\ B^T & C \end{bmatrix} \geq 0 \Leftrightarrow \begin{bmatrix} A & B \\ B^T & C \end{bmatrix} = \begin{bmatrix} u \\ v \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix}^T$$

$$\Rightarrow uu^T - uv^T[vv^T]^{-1}vu^T \geq 0.$$

Which is exactly Cauchy-Schwarts if u and v are row vectors

גיאומטריה של פונקציית פ

הוכחה:

$$f(x) = h(g(x))$$

$$f'(x) = h'(g(x))g'(x)$$

$$f''(x) = h''(g(x))(g'(x))^2 + h'(g(x))g''(x).$$

הוכחה

הוכחה של $f''(x) \geq 0$ $\Leftrightarrow h''(g(x)) \geq 0$ $\Leftrightarrow g''(x) \geq 0$ (1)

הוכחה של $f''(x) \geq 0$ $\Leftrightarrow h'(g(x)) \geq 0$ $\Leftrightarrow g'(x) \geq 0$ (2)

הוכחה של $g'(x) \geq 0 \Leftrightarrow g(x) \geq g(x_0)$ $\forall x \in \mathbb{R}$ (3)

הוכחה של $g(x) \geq g(x_0)$ $\forall x \in \mathbb{R}$ (4)

הוכחה של ג'רנרטיה

If $f(x)$ is convex, then so its perspective function $g(x,t) = tf\left(\frac{x}{t}\right)$ for $t > 0$.

הוכחה

Assume: $\text{epi}(f) = \{(x,z) : f(x) < z\}$ is convex.

Now consider: $\text{epi}(g) = \left\{ \begin{bmatrix} x \\ t \\ z \end{bmatrix} : t > 0, tf\left(\frac{x}{t}\right) \leq z \right\}$



$$\mathcal{J} = \left\{ \begin{bmatrix} x \\ t \\ z \end{bmatrix} : t > 0, f\left(\frac{x}{t}\right) \leq \frac{z}{t} \right\} =$$

ногеруму ма

$$= \left\{ (x, t, z) : t > 0, \left(\frac{x}{t}, \frac{z}{t}\right) \in \text{epi } f \right\}$$

Thus $\text{epi } g$ is the inverse image of $\text{epi } f$ under the perspective function. ■

Example: The perspective of $f(x) = x^T x$ is $g(x, t) = \frac{x^T x}{t}$ which is convex in both x and t .

עכלה מוגדרת וקטורית

We already reviewed EVD. Most square matrices can be diagonalized as: $A = UDU^{-1}$.

When they are also symmetric they can always be diagonalized as: $A = UDU^T$, where U is orthonormal.

A positive definite matrix in S_{++}^m takes us from the subspace of its eigenvectors in R^m to the same subspace in R^m . A positive semidefinite matrix is still symmetric. It does the same thing but may shrink the subspace. Some eigenvectors go to zero.

$$\text{positive semidefinite } R^n = C(A) \overset{\perp}{\oplus} N(A)$$

Given $A \geq 0$, any vector $x \in R^n$ can be written as


$$x \in R^n \Leftrightarrow x = x_1 + x_2, x_1 \in C(A), x_2 \in N(A), x_1^T x_2 = 0.$$

In terms of EVD we have:

$$A = [U_1 \ U_2] \begin{bmatrix} D_1 & 0 \\ 0 & 0 \end{bmatrix} [U_1 \ U_2]^T$$

and U_1 is a basis for $C(A)$, whereas U_2 is a basis for $N(A)$.

The four fundamental subspaces of linear algebra. Given a $m \times n$ matrix A of rank r , we have the following subspaces:



① Column Space: $C(A) \in \mathbb{R}^m$ -

all the combinations of columns of A , dimension r .

$$C(A) = \{AX : X \in \mathbb{R}^n\}$$

② Null space: $N(A) \in \mathbb{R}^n$ -

all the vectors such that $AX = 0$, dimension $n-r$.

$$N(A) = \{X \in \mathbb{R}^n : AX = 0\}$$

③ Row space: $C(A^T) \in \mathbb{R}^n$ -

all the combinations of rows of A , dimension r .

④ Left null space: $N(A^T) \in \mathbb{R}^m$ -

all the vectors such that $X^T A = 0$, dimension $m-r$.

A fundamental result:

$$\mathbb{R}^m : C(A) = [N(A^T)]^\perp$$

The null space is the orthogonal complement of the row space.

$$\mathbb{R}^n : C(A^T) = [N(A)]^\perp$$

The left null space is the orthogonal complement of the column space.



The main tool for working with non square, non-symmetric matrices is singular value decomposition.

$$(*) \quad A = UDV^T$$

where U and V are square unitary matrices and $D = \text{diag}\{\text{di}\}$ is rectangular diagonal matrix with non negative singular values.

This is very similar to EVD, except that now 4 subspaces are involved in possibly different dimensions:

$$A = \begin{bmatrix} m \times r & m \times m-r \\ U_1 & U_2 \end{bmatrix} \begin{bmatrix} r \times r & r \times n-r \\ 0 & 0 \end{bmatrix} \begin{bmatrix} n \times r & n \times n-r \\ V_1 & V_2 \end{bmatrix}^T$$

Konec.

Convex Optimization

Standard form:

$$\min_{x \in S} f_0(x)$$

$$\text{s.t. } f_i(x) \leq 0$$

$$\text{s.t. } h_i(x) = 0$$

The problem is convex if S is a convex set,
 f_i are convex functions
and $h_i(x)$ are affine functions.

Теперь мы покажем несколько трюков
Чтобы превратить задачу которую мы
получаем в convex:

: оценка ягоды. ①

$$x = \phi(z), \quad z = \phi^{-1}(x)$$

The problem is equivalent to: (надставим вместо x).

$$\min_{\phi(z) \in S} f_0(\phi(z))$$

$$\text{s.t. } f_i(\phi(z)) \leq 0$$

$$\text{s.t. } h_i(\phi(z)) = 0.$$

Indeed, when we find the optimal z^* then the optimal x^* is $x^* = \phi(z^*)$.

Example: Amplitude and phase recovery from
a noisy sine function (frequency f is known).

$$\min_{A, \phi} \sum |y_i - A \cos(2\pi f x_i + \phi)|^2$$



Non convex least squares!

Now, using a simple change of variables from polar coordinates to cartesian:

$$a_1 = A \cos(\phi)$$

$$a_2 = A \sin(\phi)$$

We obtain:

$$A \cos(2\pi f x_i + \phi) = a_1 \cos(2\pi f x_i) - a_2 \sin(2\pi f x_i)$$

And a convex Least squares:

$$\min_{a_1, a_2} \sum_i |y_i - a_1 \cos(2\pi f x_i) + a_2 \sin(2\pi f x_i)|^2$$

Градиентный метод ②

← есть ли для каждого y_i и x_i такое a_1 и a_2 , что

Example: quadratic minimization vs. norm minimization.

$$\min_x (y - Hx)^T (y - Hx) = \min_x \|y - Hx\|_2^2$$



$\min_x \|y - Hx\|_2$ - минимум один и только.

- Ищется один в шире этом трех делают квадрат корень
То есть мало кто правда решает квадратные,
а берут корень и решают обычно.



3. מינימיזציה של פונקציית נורמלית

$$\min_x f(x)$$

$$\text{s.t. } Ax = b$$

$Ax = b$: גורם שפיעם בפתרון, מופיע בפונקציית נורמלית

הנורמלית מוגדרת כפונקציית נורמלית של פונקציית נורמלית (1)

הנורמלית מוגדרת כפונקציית נורמלית (2)

(3) מינימיזציה של פונקציית נורמלית (הנורמלית מוגדרת כפונקציית נורמלית)

$$x = x_1 + x_2$$

$$Ax_1 = b$$

$$x_2 \in N(A).$$

לפיה מינימיזציה של פונקציית נורמלית

$$\min_{x_2} f(x_1 + x_2)$$

$$\text{s.t. } x_2 \in N(A)$$

$$\min_z f(x_1 + Fz)$$

כדי שפונקציית נורמלית תהיה מינימלית, על x_1 להיות נורמלית.

נורמליזציה.

Example: $\min_{x \in \mathbb{R}^n} f(x_1, x_2, \dots, x_n)$

$$\text{s.t. } \sum_{i=1}^n x_i = 0$$

→ Сумма каждого вектора ноль.

Поэтому у суммы какое-то значение, которое не '0', а потом отнимем.

$$\min_{z \in \mathbb{R}^{n-1}} f(z_1, z_2, \dots, z_{n-1}, -\sum_{i=1}^{n-1} z_i)$$



(4) מינימיזציה

$$\min_x f(Ax + b)$$

$$\min_{x,z} f(z)$$

$$\text{s.t. } z = Ax + b.$$

הוכחה של נימיניזציה: מינימיזציה של $f(x)$ בקבוצה S :

אם $f(x)$ היא פונקציית אמצעים של $f(x)$ בקבוצה S .

$$\min_{x \in S} f(x)$$

$$\min_x f(x)$$

בנוסף קיימת S

$\forall y \in S: \nabla^T f(x)(y - x) \geq 0$ כלומר y מינימום מקומי של $f(x)$.

הוכחה:

נוכיח כי הנקודה x היא חסנה. \Rightarrow

אזי, על מנת $x, y \in S$ ו- y מינימום מקומי של f .

$$f(y) \geq f(x) + \nabla^T f(x)(y - x)$$

ולפונקציית f מינימלית.

אנו נוכיח ש $f(x)$ מינימום מקומי של f .

$$f(x) + \nabla^T f(x)(y - x) \geq f(x)$$

ה(ה)רשות חסנה

נוכיח ש $f(x)$ מינימום מקומי של f .

\Leftarrow נוכיח כי x מינימום מקומי של f , כלומר $\nabla^T f(x)(y - x) \leq 0$ $\forall y \in S$.

$\forall y \in S: \nabla^T f(x)(y - x) \leq 0$

נוכיח נגדי:

$$z(t) = (1-t)x + ty \quad t \in [0, 1]$$

תהי $y \neq x$ ניכיל לא y .



$$f(z(t)) < f(x(t)) \quad \text{или} \quad \nabla f^\top(x)(y-x) < 0$$

$$\frac{df(z(t))}{dt} \Big|_{t=0} = \nabla f^\top(x)(y-x) < 0$$

- Если увидим что спускаем, то спускаем.
- $z(0)$ это и есть x . Если движемся, то уменьшаем a это шаг, так как x и z минимум.

Two famous special cases:

Unconstrained convex optimization:

A necessary and sufficient condition for optimality is :

$$\nabla f(x) = 0$$

Since the condition must hold for

$$y = x+z \text{ and } y = x-z \text{ for any } z.$$

That's:

$$z = y - x \text{ and } z = -(y - x)$$

According to the theorem we know that x is global minimum iff $\nabla^\top f(x)(y-x) \geq 0$. Yes.

$$\begin{aligned} \nabla^\top f(x)(y-x) &= \\ &= \nabla^\top f(x)z \geq 0 \quad \forall z \end{aligned}$$

$$\nabla^\top f(x)z \leq 0 \quad \forall z$$

This holds only if gradient is identically 0.



- Convex scalar minimization on an interval I

$I = \{a \leq x \leq b\}$, a necessary and sufficient condition for optimality is $x \in I$ and $f'(x)(y-x) \geq 0, \forall y \in I$.

- Now if x is strictly inside the interval, then as before the condition reduces to $f'(x) = 0$.

- If it is on the border, e.g., $x=b$ then for all $y \in I$ we have $y-x \leq 0$, and the condition reduces to $f'(x) \leq 0$, which means that the end point is a global minimizer.

Convex Optimization Problems

1. Least Squares:

$$\min_x \|Ax - b\|_2^2$$

This is of course an unconstrained convex optimization problem (with and without the square as it is a norm or positive definite quadratic form).

Least squares' optimality conditions are:

$$\nabla f(x) = A^T(Ax - b) = 0.$$

* Как на негл. смотрите.

Ищем оптимум.

→ For an unconstrained problem (i.e $m=p=0$) the condition of the "deriv > 0" reduces to necessary and sufficient condition $\nabla f_0(x)=0$.

Case 1:

A is square invertible matrix.

$AX = b$ has a unique solution which satisfies the optimality conditions

$$x = A^{-1}b$$

Case 2:

Less equations than unknowns.

$AX = b$ has infinite solutions all of which are optimal as they satisfy the optimality conditions.

→ The Hessian has zero eigenvalues as $A^T A$ is a large matrix with small rank. ($\text{gilkelen pánik}, n < K$)

$$\begin{matrix} n & \boxed{A} \\ & K \end{matrix} \rightarrow \begin{matrix} n \\ A^T \\ K \end{matrix}$$

$\text{gib} \mathcal{G}_N = \text{gib} \mathcal{G}_{K_N}$

Rank = is the dimension of the vector space generated (or spanned) by its columns.

→ However, AA^T is a small matrix, usually of full rank and invertible, and it is easy to verify that one solution is:

$$x_0 = \underset{n \times n}{A^T} \underset{n \times n}{(AA^T)^{-1}} b = \underset{n \times 1}{A^T} b.$$

A^+ : is known as the Moore-Penrose generalized inverse (aka pseudo-inverse) of A .

$$\begin{aligned} A^T(Ax - b) &= A^T(A(A^T(AA^T)^{-1}b) - b) = A^T(AA^T(AA^T)^{-1}b - b) = \\ &= A^T(b - b) = 0. \end{aligned}$$

\downarrow $\text{gib} \mathcal{G}_N$

This is one solution and the rest can be characterized as:
 $x = x_0 + z$, $z \in N(A)$.

Case 3:

More equations than unknowns.


$Ax = b$ has no solutions, but we can still search for the least squares approximation. We need to solve:

$$A^T A x = A^T b$$

Почему?: $\nabla f = A^T (Ax - b) = 0$

Это можно решить? не получим

В форме рисунков получаем:

 do это все не можем обнулить.
Least squares пред назначаем это
"Onyemum6".

- "Onyemum6" = A^T (транспоз.) $\boxed{A^+}$.

$$A x = b \quad \downarrow \text{Onyemum}$$

$$A^T A x = A^T b$$

$$x = \boxed{(A^T A)^{-1}} A^T b$$

pseudo inverse

$$x = A^+ b.$$

To conclude:

In all cases the LS solution is $x = A^+ b$.

It coincides with the inverse if A is square and invertible, but otherwise has different meanings.

What happens when the rows/columns
are NOT linearly independent?

- The solution is still the A^+b and the pseudo-inverse always exists and is unique.

→ To gain intuition we will see the scalar case.

$$\min_x \|ax - b\|^2$$

$$2a(ax - b) = 0$$

From

$$ax - b = 0$$

From

$$x = \frac{b}{a}$$

To be consistent with previous solutions, we define

$$x^+ = \begin{cases} \frac{1}{a}b & a \neq 0 \\ 0 & a = 0 \end{cases}$$

⇒ The general case:

$$Ax = b \quad \text{Onychkaem } A = UDV^\top \text{ (according to SVD)}$$

$$A^T A x = A^T b$$

SVD

$$V D^\top U^\top U D V^\top X = V D^\top U^\top b$$

$$X D^\top D V^\top X = X D^\top U^\top b$$

$$D^\top D \underbrace{V^\top X}_{\tilde{X}} = D^\top U^\top \underbrace{b}_{\tilde{b}} \quad \text{- diagonalized the system.}$$

$$\frac{d_i}{d_i^2} = \frac{1}{d_i} = d_i^+$$

$$\downarrow d_i^2 \tilde{x}_i = d_i \tilde{b}_i$$

$$\tilde{x}_i = d_i^+ \tilde{b}_i$$

$$(A^+ = A^\top (A A^\top)^{-1})$$

$$\tilde{x}_i = d_i + \tilde{b}_i$$

$$\tilde{x} = D^+ \tilde{b}$$



Получим обратно:

$$V^T x = D^+ U b$$

$$x = \underbrace{VD^+U^T}_{A^+} b = A^+ b \quad , \Rightarrow A^+ = VD^+U^T$$

$$x = A^+ b.$$



2. Problems with equality Constraints only

$$\min_{x: Ax=b} f(x)$$

① The optimality conditions are:

$$\nabla f(x)^T (y-x) \geq 0 \quad \forall y \quad Ay=b, y \in S$$

② Since x is feasible, then $y = x + v$ where $v \in N(A)$
and therefore: $y - x = v$

$$\nabla f(x)^T v \geq 0, \quad \forall v \in N(A)$$

③ If a linear function is nonnegative on a subspace,
then it must be zero on the subspace.

So it follows that:

$$\nabla f_0(x)^T v = 0 \text{ for all } v \in N(A)$$

In other words:

$$\nabla f_0(x) \perp N(A)$$

null space \perp row space

④ Using the fact that $N(A)^\perp = C(A^T)$, this optimality condition
can be expressed as $\nabla f_0(x) \in C(A^T)$. i.e., there exists a
 $v \in \mathbb{R}^p$ such that:

$$\nabla f_0(x)^T + A^T v = 0$$

⑤ Together with the requirement $Ax=b$ (i.e. that x is feasible),
this is a classical Lagrange multiplier optimality condition.

3. MINIMIZING PROBLEMS

Least-squares solution of linear equations

- ① The most common least-norm problem involves the Euclidean or ℓ_2 -norm. By squaring the objective we obtain the equivalent problem.

$$\text{minimize } \|x\|_2^2$$

$$\text{s.t. } Ax = b$$

- ② Introducing the dual variable $v \in \mathbb{R}^m$, the optimality conditions are:

$$2x^* + A^T v^* = 0, \quad Ax^* = b.$$

- ③ This is a pair of linear equations, and readily solved.

From the first equation:

$x^* = -\frac{1}{2}A^T v^*$, substituting it into the second equation we obtain:


$$-\frac{1}{2}AA^T v^* = b \quad \text{and conclude:}$$

$$v^* = -2(AA^T)^{-1}b.$$

$$x^* = -\frac{1}{2}A^T \cdot (-2)(AA^T)^{-1}b = \\ = A^T(AA^T)^{-1}b = A^+b. \quad \blacksquare$$



4. Projections:



Обычай увел:

Хотим найти элемент в группе S , который больше всего похоже на элемент z .

- ① Now we define the projection of z onto a convex set S .

$$P_S(z) = \underset{x \in S}{\operatorname{argmin}} \|x - z\|$$

- ② We will start with projections onto a subspace (which is of course a convex set)

$$S = \{x : x = Ay \text{ for some } y\}$$

A the column space \rightarrow in S looks

- ③ Where A is a tall matrix (more rows than columns)

$$\underset{\{x : x = Ay \text{ for some } y\}}{\operatorname{min}} \|x - z\|$$

- ④ And now we get: (мptok = nepebecmu б уюум)

$$\begin{aligned} & \underset{\substack{x, y \\ \text{s.t.}}}{} \min \|x - z\| \\ & \quad x = Ay \end{aligned}$$

- ⑤ We eliminate the linear constraints:

$$\underset{y}{\operatorname{min}} \|Ay - z\|$$

- ⑥ And the solution is clearly

$$y^* = A^+ z$$

⑦ And in terms of x :

$$x^* = Ay^* = AA^+z$$

⑧ So that:

$$P_S(z) = AA^+z$$

(c.space) $S = C(A)$ for some \in linear space

① The optimality conditions read:

$$(x^* - z)^T(x - x^*) \geq 0, \forall x \in C(A)$$

② $x \in C(A)$

It means that $x - x^*$ also $\in C(A)$

③ And basically we have:

$$(x^* - z)^T \geq 0, \forall x \in C(A)$$


④ This is true for x and $-x$ so

$$(x^* - z)^T x = 0, \forall x \in C(A)$$

Which means that the error (gradient) is orthogonal to the range of A . Otherwise we can improve.



הוכחה של גאון



Given S is convex, closed and bounded

① $\exists z \in \text{cl}(S)$ such that $(x^* - z)^\top (x - x^*) \leq 0$

② $x^* = \text{Ps}_S(z)$ (meaning x^* is the projection of z onto S)

and

$$(\#) (\#) (z - x^*)^\top (x - x^*) \leq 0 \quad \forall x \in S$$

③ the proof is by contradiction:

$$(\#) \| \text{Ps}_S(x) - \text{Ps}_S(y) \|_2 \leq \|x - y\|_2 \quad \forall x, y.$$

$$\Rightarrow z - z' \leq \|x - y\|$$

No such z' :

④ there is no z' in S such that $\|x - z'\| = \|x - y\|$

⑤ x^* is unique since $\|x - z\| = \|x - y\|$

⑥ $\text{Ps}_S(z) = x^*$ (projection is unique)

תיכונה:

① We will only give a sketch of a proof.

Skip existence.

Uniqueness is due to strict convexity.

② Non-expansive:

Consider some x and y .

Then $\text{Ps}_S(x)$ and $\text{Ps}_S(y)$ are in S and the optimality conditions yield: ($x^* = \text{Ps}_S(x)$ and $y^* = \text{Ps}_S(y)$ for some x^*, y^*)

$$(z - x^*)^\top (x - x^*) \leq 0$$



$$(\text{Ps}_S(y) - \text{Ps}_S(x))^\top (x - \text{Ps}_S(x)) \leq 0$$

for every z
unique projection

$$(\text{Ps}_S(x) - \text{Ps}_S(y))^\top (y - \text{Ps}_S(y)) \leq 0$$

y^*



Add this up to obtain:

$$(P_s^{\textcolor{red}{a}}(x) - P_s^{\textcolor{blue}{b}}(y))^T (x - P_s^{\textcolor{red}{a}}(x) - y + P_s^{\textcolor{blue}{b}}(y)) \leq 0$$

$$(a - b)^T (x - a - y + b) \leq 0$$

$$(a^\top - b^\top)(x - a - y + b) \leq 0$$

$$a^\top x - a^\top a - a^\top y + a^\top b - b^\top x + b^\top a + b^\top y - b^\top b \leq 0 \quad | \cdot (-1)$$

$$-a^\top x + a^\top a + a^\top y - a^\top b + b^\top x - b^\top a - b^\top y + b^\top b \geq 0$$

$$a^\top a - a^\top b - b^\top a + b^\top b \geq a^\top x - a^\top y - b^\top x + b^\top y$$

$$\|a - b\|_2^2 \geq y(b^\top - a^\top) - x(b^\top - a^\top)$$

$$\|a - b\|_2^2 \geq (b^\top - a^\top)(y - x)$$

$$\|P_s(x) - P_s(y)\|_2^2 \geq (P_s(y) - P_s(x))^T (y - x)$$

$$\|P_s(y) - P_s(x)\|_2^2 \leq (P_s(y) - P_s(x))^T (y - x)$$

Cauchy schwarts: $a^\top b \leq \|a\| \cdot \|b\|$.

$$\|P_s(y) - P_s(x)\|_2^2 \leq (P_s(y) - P_s(x))^T (y - x) \stackrel{\downarrow \text{C.S.}}{\leq} \|P_s(y) - P_s(x)\| \cdot \|y - x\|$$

$$\|P_s(y) - P_s(x)\|_2^2 \leq \|P_s(y) - P_s(x)\| \cdot \|y - x\|.$$

$$\|P_s(y) - P_s(x)\| \leq \|y - x\|_2. \blacksquare$$



Example: Projection onto the semidefinite cone
(with frobenius norm)

$$S = \{X : X \geq 0\}$$

p.s.d & ∞ norm

$$Y = UDU^T \quad (\text{s.v.d})$$

$$X = \underset{X \geq 0}{\operatorname{argmin}} \|X - Y\|^2$$

Now, $X \geq 0$ is optimal iff :

$$\operatorname{Tr}\{(Y-X)(Z-X)\} \leq 0, \forall Z \geq 0.$$

Lets guess: $X = U[D]_+ U^T$ then $X \geq 0$ and:

$$\operatorname{Tr}((Y-X)(Z-X)) = \underbrace{\operatorname{Tr}((Y-X)Z)}_A - \underbrace{\operatorname{Tr}((Y-X)X)}_B \leq 0.$$

$$A: \operatorname{Tr}(U(D)_+ U^T Z) = \operatorname{Tr}(D_+ Z)$$

$$B: \begin{aligned} &(\text{if } y > 0 \text{ mo } y^* = y = 0) \\ &(\text{if } y < 0 \text{ mo } y^* = 0). \end{aligned} \quad = \text{zero}$$

$$B \Rightarrow \operatorname{Tr}((Y-X)X) = \operatorname{Tr}(YX) - \operatorname{Tr}(X^2) =$$

$$= \operatorname{Tr}(YUDU^T U[D]_+ U^T) - \operatorname{Tr}(UD_+ U^T U[D]_+ U^T) =$$

\downarrow

$$= \operatorname{Tr}(DD_+) - \operatorname{Tr}(DD_+) = 0. \blacksquare$$

הוכחה:

$$(BA = AB \quad : \text{ונגזר (כגון)} \quad \text{בנוסף ל} \quad B \geq A \quad \text{ולכ} \quad ①)$$

$$\text{Tr}(AB) \geq 0. \quad : \text{ונדרשו} \quad A, B \geq 0 \quad \text{ולכ}$$

הוכחה:

$$B = LL^T \quad : \text{ונעשית}$$

$$\begin{aligned} \text{Tr}(A L L^T) &= \text{Tr}(L^T A L) = \\ &= \sum \ell_i^T A \ell_i \geq 0. \blacksquare \end{aligned}$$

$$B^{-1} \leq A^{-1} \quad : \text{ולכ, } B \geq A \geq 0 \quad \text{ולכ} \quad ②$$

הוכחה:

$$D_B \geq D_A \quad : \text{ונעשית. לפיכך -}$$

$$A = U D_A U^T$$

$$B = U D_B U^T$$

$$\frac{1}{D_{Aii}} \leq \frac{1}{D_{Bii}} \quad : \text{ולכ}$$

מכיל אוניברסיטאות

U נסימן באלו סימני U

טוטו. כמו שוניה וטוטו I יתפרק לאלו.

טוטו גנטיאן סימני I יתפרק לאלו.



Linear Programming

- Linear functions are concave and therefore the solutions to LP always lie on extreme points.

Standard form: $\begin{array}{l} \min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} \\ \text{s.t. } \mathbf{Gx} \leq \mathbf{h} \\ \mathbf{Ax} = \mathbf{b} \end{array}$

Some examples:

- Показываем какие задачи могут быть выражены как LP.

1. Power Control:

הנתקה הינה גורם של הנתקה ברכיב כוח נזקינו ניטר. זא"ה הינה אוניברסלית להתקה רציפה כ:

$$\log \left(1 + \frac{h_i p_i}{\sigma^2 + \sum h_j p_j} \right) \geq \gamma_i$$

הוכן
גסן
גסן נזקינו ניטר. (בז'ונטער נזקינו ניטר)

$$\Rightarrow \min_{p_i} \sum_i p_i$$

s.t. $\log \left(1 + \frac{h_i p_i}{\sum_{j \neq i} p_j h_{ij} + \sigma^2} \right) \geq \gamma_i$

$$p_i \geq 0$$

$$\Rightarrow \min_{p_i} \sum_i p_i$$

$$\text{s.t. } \frac{h_i p_i}{\sum_{j \neq i} p_j h_{ij} + \sigma^2} \geq e^{\gamma_i} - 1$$


$$p_i \geq 0$$

$$\Rightarrow \min_{p_i} \sum_i p_i$$

$$\text{s.t. } h_i p_i \sum_{j \neq i} p_j h_{ij} + \sigma^2 \geq \sum_{j \neq i} p_j (e_i^{t-1}) h_{ij} + (e_i^{t-1}) \sigma^2$$

$$p_i \geq 0$$

2. Piecewise linear minimization



The problem: $\min_x f(x)$

$$\left\{ \begin{array}{l} \min_x \max_i a_i^T x + b_i \end{array} \right.$$

can be reformulated:

$$\left\{ \begin{array}{l} \min_{x,t} t \\ \text{s.t. } \max_i a_i^T x + b_i \leq t \end{array} \right.$$

$$\left\{ \begin{array}{l} \min_{x,t} t \\ \text{s.t. } a_i^T x + b_i \leq t \quad \forall i \end{array} \right.$$

$$\left\{ \begin{array}{l} \min_{x,t} t \\ \text{s.t. } Ax + b \leq t \end{array} \right.$$

Note: can be written as

$$\min_x \|Ax + b\|_\infty$$



3. L_1 minimization

$$\min_x \|Ax - b\|_1$$

→ Эта норма наказывает нас меньше в случае ошибки. Хотим чтобы ошибка была sparse.
Норма L_1 квадра.

$$\begin{cases} \min_{x,t} 1^T t \\ \text{s.t. } t_i = |a_i^T x + b_i| \quad \forall i \end{cases}$$

- Relaxing the equality to an inequality :

$$\begin{cases} \min_{x,t} 1^T t \\ \text{s.t. } t_i \geq |a_i^T x + b_i| \quad \forall i \end{cases}$$

- Open the $| \cdot |$:

$$\begin{cases} \min_{x,t} 1^T t \\ \text{s.t. } -t_i \leq a_i^T x + b_i \leq t_i \quad t_i \geq 0 \end{cases}$$

→ Together with the previous example both L_1 and L_∞ norm minimizations can be expressed as LP.



4. Linear Fractional Programming

* Обычай схема работы:

Мы добавляем большие параметров и тем самым увеличиваем наш тхум.

- Всегда ищем хасам тахтот - что означает приблизить разумный радиус к тхуму.
- Хасам тахтот потому - что $\min(x)$ даст теперь значения которые меньше и им не разрешено быть в тхуме.

- Мы добавляем иллюм чтобы:
- "Приподнять в воздух и потом бросить!"
- В начале нам будут не нужны, но когда бросим киркут, они понадобятся.



Начало:

$$\left\{ \begin{array}{l} \min_{x: c^T x + f > 0} \frac{c^T x + d}{c^T x + f} \\ \text{s.t. } Gx \leq h \\ Ax = b \end{array} \right.$$

לעומת מינימיזציה של פונקציית נומינון: מינימיזב נומינון
מינימיזב גלגולן ב

$$y = \frac{x}{c^T x + f}, z = \frac{1}{c^T x + f} \quad : \text{מינימיז} \quad ①$$



→ В конце мы выбросим 'y' и 'x' так как они не приемные для работы и вообще не интересные.

Но же этого, вытащим из них по максимум информации (лиши на рисунке).

We will add the following constraints:

$$* z > 0$$

$$* y = zx, \quad x = \frac{y}{z}.$$

$$* y = \frac{x}{e^T x + f} \stackrel{x \rightarrow 0}{\approx} \frac{\frac{y}{z}}{e^T \frac{y}{z} + f} = \frac{y}{e^T y + fz} \Rightarrow \\ \Rightarrow e^T y + fz = 1.$$

$$* Gx < h$$

$$G \cdot \frac{y}{z} < h$$

$$Gy < hz$$

$$* Ax = b$$

$$A \frac{y}{z} = b$$

$$Ay = bz$$

New problem: dropping the x:

$$\min_{y,z} c^T y + dz$$

$$\text{s.t. } Gy < hz$$

$$Ay = bz$$

$$z > 0$$

$$e^T y + fz = 1.$$

\Rightarrow נון LP זיהוי מינימום כרך נון LP \Leftarrow
 \Rightarrow מינימום כרך LP זיהוי מינימום LP \Leftarrow


Compressed Sensing

- A different example where we look for an approximation of a non-convex combinatorial optimization.
- The problem is again solving a linear system of equations $Ax = b$. But we assume less equations than unknowns, hence infinite solutions.
We already learned the minimum L2 norm solution $x = A^+b$.
- In some settings (which are very common) we have additional prior knowledge that x is sparse.
Thus we would like to solve:

$$\begin{array}{ll} \min_x & \|x\|_0 \\ \text{s.t.} & Ax = b \end{array}$$

where:

$$\|x\|_0 = \text{card}(x), \quad \text{card}(z) = \begin{cases} 1 & z \neq 0 \\ 0 & z = 0 \end{cases}$$



Как у рисунке: есть наименее хакам максимум
(наименее ортогональные наши ортогональные).



- The vector is just the sum, whenever it's one.
- The envelope of scalar $\text{card}(x)$ on $[-1, 1]$ is $|x|$.
- The envelope of vector $\text{card}(x)$ on $\{x : \|x\|_\infty \leq R\}$ is $\frac{1}{R} \|x\|_1$.

Thus we propose to solve:

$$(\text{GMIN prob}) \begin{cases} \min_x \|x\|_1 \\ \text{s.t. } Ax = b. \end{cases}$$



Can be formulated as:

$$\begin{cases} \min_{x, t} 1^\top t \\ \text{s.t. } Ax = b \\ -t \leq x \leq t. \blacksquare \end{cases}$$



Second Order Cone Programming

(LP \rightarrow SOCP \rightarrow SDP).

$$\min_x f^T x$$

$$\text{s.t. } \|A_i x + b_i\| \leq c_i^T x + d_i \quad \forall i$$

① Taking $A_i = b_i = 0$ leads to a simple linear programm.

② Taking $c_i = 0$ and $d_i \geq 0$ leads to a simple quadratic program (QP).

- But it is more general than QP as it allows one negative eigenvalue as long as rhs is positive.

- LP $\exists m o X \geq 0$, Semi Definite $\exists m o M > 0$
A SOCP $\exists m o$

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \underset{\text{SOCP}}{\leq 0} \Rightarrow \left\| \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \right\| \leq x_3$$

Example: 1 Quadratic Set

$$\{x^T A^T A x + b^T x + c \leq 0\} \Leftrightarrow \left\| \frac{1+b^T x + c}{2} \right\|_{AX} \leq \frac{1-b^T x - c}{2}$$

pkc u pki
 ↓

לעכ:

① SOCP = Quad + LIN

$$\left\| \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \right\| \leq x_3 \Leftrightarrow \left\| \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \right\|^2 \leq x_3^2 \text{ and } x_3 \geq 0.$$

② Всегда поднимай в квадрат обе стороны.

③ И требуй чтобы правая часть была больше 0.

④ Bom:

* $\frac{1 - b^T x - c}{2} \geq 0 \Rightarrow b^T x + c \leq 1$ פוליך

* Поднимай в квадрат:

$$\left(\frac{1 + b^T x + c}{2} \right)^2 + x^T A^T A x \leq \left(\frac{1 - b^T x - c}{2} \right)^2$$

$$x^T A^T A x + b^T x + c \leq 0 \text{ פוליך}$$

כדי שפונקציית האנרגיה תהיה גאוזיאלית נדריכים



Example 2: Hyperbolic Constraints

$$\begin{cases} w : w^T w \leq xy \\ x : x \geq 0 \\ y : y \geq 0 \end{cases}$$

המקרה 1: $w^T w \leq xy$

1) הוכיחו שקיימת נקודה (x,y) המקיימת את התנאי $w^T w \leq xy$.

הוכחה: נסמן $\omega = (w, 1)^T$

2) הוכיחו שקיים מינימום מקומי לאטום של $w^T w$.

$$\begin{cases} \|2w\| \leq x+y \\ x-y \end{cases} : \text{SOCP} \quad (3)$$

* יהווים בքדרם:

$$(2w)^2 + (x-y)^2 \leq (x+y)^2$$

$$4w^2 + x^2 - 2xy + y^2 \leq x^2 + 2xy + y^2$$

$$4w^2 \leq 4xy$$

$$0 < w^T w \leq xy.$$

↙
Քառակույթ

* בולבוי 0: $x+y \geq 0$.

$$\begin{cases} x+y \geq 0 \\ xy \geq 0 \\ w^T w \leq xy \end{cases} \Rightarrow \begin{cases} x \geq 0 \\ y \geq 0 \end{cases} \quad \blacksquare$$



Example 3: Minimizing the harmonic mean
of positive functions over a polytope:
: YINII PBO

$$\begin{cases} \min_x \sum \frac{1}{a_i^T x + b_i} \\ \text{s.t. } a_i^T x + b_i > 0 \\ c_i^T x + d_i \geq 0 \end{cases}$$

: PJOEN PROJ

$$\begin{cases} \min_{x, t_i} \sum t_i \\ \text{s.t. } a_i^T x + b_i > 0 \\ c_i^T x + d_i \geq 0 \\ t_i = \frac{1}{a_i^T x + b_i} \Leftrightarrow t_i(a_i^T x + b_i) = 1. \end{cases}$$

It's only better to decrease t_i ,
so we can make the equality an inequality:

$$\begin{cases} \min_{x, t_i} \sum t_i \\ \text{s.t. } a_i^T x + b_i > 0 \\ c_i^T x + d_i \geq 0 \\ t_i(a_i^T x + b_i) \geq 1 \\ t_i \geq 0. \end{cases}$$

As SOCP:

$$\left\| \begin{array}{c} 2 \cdot 1 \\ t_i - (a_i^T x + b_i) \end{array} \right\| \leq t_i + (a_i^T x + b_i)$$



ЛПрок SOCP:

$$\|x\|_2 \leq yz \Rightarrow \left\| \begin{array}{c} 2x \\ y-z \end{array} \right\| \leq y+z$$

- * Всегда ищем где норма.
- * Ее без квадрата умножаем на 2.
- * То что больше нормы - разделяем на минус и плюс.

Robust Linear Programming:

$$\left\{ \begin{array}{l} \min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} \\ \text{s.t. } \mathbf{a}_i^T \mathbf{x} \leq b_i \quad \forall i \in S_i \\ \text{where:} \\ S_i = \{\bar{a}_i + P_i u : \|u\|_2 \leq 1\} \end{array} \right.$$

MINP ဂ"ვა

- The constraint:

$$\left. \begin{array}{l} \mathbf{a}_i^T \mathbf{x} \leq b_i \quad \forall i \in S_i \\ \text{is equivalent to} \\ \max_{\mathbf{a} \in S_i} \mathbf{a}^T \mathbf{x} \leq b_i \end{array} \right\} \begin{array}{l} \text{из всей группы берем} \\ \text{максимум.} \end{array}$$

↑ работает и в другую сторону.

$$\left. \begin{array}{l} \text{представляем} \\ \text{or equivalent to} \\ \max_{\mathbf{u}: \|\mathbf{u}\|_2 \leq 1} (\bar{a}_i + P_i \mathbf{u})^T \mathbf{x} \leq b_i \end{array} \right\}$$

Открываем скобки, и то что не относится к ' \mathbf{u} ' выносим.

$$\bullet \bar{a}_i^T \mathbf{x} + \left\{ \max_{\mathbf{u}: \|\mathbf{u}\|_2 \leq 1} \mathbf{u}^T P_i^T \mathbf{x} \right\} \leq b_i$$

}

$$\left\{ \max_u u^\top P_i^\top x \right\}_{u: \|u\|_2 \leq 1} b_i$$



Using Cauchy Schwartz:

$$u^\top P_i^\top x \leq \|u\| \cdot \|P_i^\top x\| = \|P_i^\top x\|$$

\downarrow
 $u=u^*$

achievable by choosing

$$u = \frac{P_i^\top x}{\|P_i^\top x\|}$$

Thus, we get SOCP:

$$\min_x C^\top x$$

$$\text{s.t. } \bar{a}_i^\top x + \|P_i^\top x\| \leq b_i$$

XI. SEMIDEFINITE PROGRAMMING

SDP:

A higher level in the conic programming hierarchy: LP, SOCP and SDP. Basically an LP with a different definition of the inequalities.

$$\begin{aligned} \min_x \quad & c^T x \\ \text{s.t.} \quad & F_0 + \sum_i x_i F_i \succeq 0 \\ & Ax = b \end{aligned}$$

LMI = Linear matrix inequality

Multiple LMIs via a single block diagonal LMI.

LP is special case by choosing scalar F_0 and F_i .

SOCOP is special case by noting that

$$\{x, t : \|x\|_2 \leq t\} = \left\{ x, t : \begin{bmatrix} tI & x \\ x^T & t \end{bmatrix} \succeq 0 \right\}$$

Example: matrix fractional program can be cast as as SOCP and therefore also as SDP (which is much more natural yet more expensive)

$$\begin{cases} \min_x \quad (Ax + b)^T (I + B \text{diag}\{x\} B^T)^{-1} (Ax + b) \\ \text{s.t.} \quad x \geq 0 \end{cases}$$

Adding variables

$$\begin{cases} \min_{x,t} \quad t \\ \text{s.t.} \quad \underbrace{t \geq (Ax + b)^T}_{A} \underbrace{(I + B \text{diag}\{x\} B^T)^{-1}}_{C^{-1}} \underbrace{(Ax + b)}_{B^T} \\ \quad x \geq 0 \end{cases}$$

Now using Schur's lemma : $(A - BC^{-1}B^T \succeq 0) \Leftrightarrow \begin{bmatrix} A & B \\ B^T & C \end{bmatrix} \succeq 0$

$$\begin{cases} \min_{x,t} \quad t \\ \text{s.t.} \quad \begin{bmatrix} t & (Ax + b)^T \\ (Ax + b) & (I + B \text{diag}\{x\} B^T) \end{bmatrix} \succeq 0 \\ \quad x \geq 0 \end{cases}$$

A. Minimization of maximum eigenvalue (symmetric)

$$A(X) = A_0 + \sum_i x_i A_i \quad \text{symmetric}$$

We want to solve

$$\min_x \lambda_{\max}(A(x))$$

$$\begin{cases} \min_{x,t} t \\ \text{s.t.} \quad \lambda_{\max}(A(x)) \leq t \end{cases}$$

непхог на "где Кангоро"

$$\begin{cases} \min_{x,t} t \\ \text{s.t.} \quad \lambda_i(A(x)) \leq t \quad \underline{\underline{i}} \end{cases}$$

$$\{\lambda_i(A) \leq t \forall i\} = \{A \leq tI\}$$

Ombem:

$$\boxed{\begin{cases} \min_{x,t} t \\ \text{s.t.} \quad A(x) \preceq tI \end{cases}}$$

B. Minimization of spread of eigenvalues (symmetric)

$$A(X) = A_0 + \sum_i x_i A_i \quad \text{symmetric}$$

We want to solve

$$\min_x \lambda_{\max}(A(x)) - \lambda_{\min}(A(x))$$

$$\begin{cases} \min_{x,t_1,t_2} t_1 - t_2 \\ \text{s.t.} \quad \lambda_{\max}(A(x)) \leq t_1 \\ \quad \quad \quad \lambda_{\min}(A(x)) \geq t_2 \end{cases}$$

Ombem:

$$\begin{cases} \min_{x,t_1,t_2} t_1 - t_2 \\ \text{s.t.} \quad t_2 I \preceq A(x) \preceq t_1 I \end{cases}$$

C. Matrix norm minimization (non-symmetric)

$$A(X) = A_0 + \sum_i x_i A_i \quad \text{non symmetric}$$

We want to solve

$$\min_x \|A(x)\|_2$$

where $\|X\|_2$ is the maximum singular value of X , is the square root of the maximum eigenvalue of $X^T X$, and also the maximum eigenvalue if $X \succeq 0$. This is convex because it is a norm.

$$\min_x \lambda_{\max}(A^T(x) A(x))$$

$$\left\{ \begin{array}{l} \min_{x,t} t^2 \\ \text{s.t. } \lambda_{\max}(A^T(x) A(x)) \leq t^2 \end{array} \right.$$

$$\left\{ \begin{array}{l} \min_{x,t} t \\ \text{s.t. } A^T(x) A(x) \preceq t^2 I \end{array} \right.$$

$$\{A^T A \preceq t^2 I\} \stackrel{\text{determinant}}{\downarrow} \left\{ A, t : \begin{bmatrix} tI & A \\ A^T & tI \end{bmatrix} \succeq 0 \right\}$$

Ombrem:

$$\left\{ \begin{array}{l} \min_{x,t} t \\ \text{s.t. } \begin{bmatrix} tI & A(x) \\ A^T(x) & tI \end{bmatrix} \succeq 0 \end{array} \right.$$

D. Fastest mixing Markov chain on a graph

Fastest mixing Markov chain on a graph - also related to fastest distributed computation of mean via consensus.

We consider an undirected graph $G = \{V, E\}$ with $|V| = n$. We allow self-loops, i.e., $(i, i) \in E$. We define a Markov chain with states V and transitions E with probabilities P_{ij} for $(i, j) \in E$.

$$P = P^T \quad \text{undirected and symmetric}$$

$$1^T P = 1^T \quad \text{probabilities sum to one}$$

$$P \geq 0 \quad \text{probabilities are not negative}$$

$$P_{ij} = 0 \ (i, j) \notin E \quad \text{transitions only on edges}$$

The first two properties show that $\frac{1}{n}1$ is an equilibrium stationary distribution and this is the largest eigenvalue.

Convergence to the stationary distribution is determined by the second largest (in magnitude) eigenvalue, denoted by r . This can be either λ_2 or $-\lambda_n$ where

$$1 = \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$$

Thus,

$$r = \max\{\lambda_2, -\lambda_n\}$$

When $r = 1$ convergence is not promised. When $r < 1$ the smaller r is, the faster the mixing.

Thus, we want to solve

$$\min_P \max\{\lambda_2, -\lambda_n\}$$

$$\text{s.t. } P = P^T$$

$$P \geq 0$$

$$1^T P = 1^T$$

$$P_{ij} = 0 \ (i, j) \notin E$$

The principal eigenvalue is λ_1 so we cannot use the spectral norm as is. We need to first remove the first eigenvalue. Its eigenvector is $\frac{1}{\sqrt{n}}1$ so we can project P on the orthogonal complement

$$[1]^\dagger = \frac{1^T}{1^T 1}$$

and the projection operator is

$$Q = I - \frac{11^T}{1^T 1}$$

so that

$$\begin{aligned} r &= \|QPQ\|_2 \\ &= \|P - \frac{11^T}{1^T 1}\|_2 \end{aligned}$$

and we get

$$\begin{aligned} \min_P \quad & \|P - \frac{11^T}{1^T 1}\|_2 \\ \text{s.t.} \quad & P = P^T \\ & P \geq 0 \\ & 1^T P = 1^T \\ & P_{ij} = 0 \ (i, j) \notin E \end{aligned}$$

$$\begin{aligned} \min_{P,t} \quad & t \\ \text{s.t.} \quad & |\lambda_i \left(P - \frac{11^T}{1^T 1} \right)| \leq t \quad \forall i \\ & P = P^T \\ & P \geq 0 \\ & 1^T P = 1^T \\ & P_{ij} = 0 \ (i, j) \notin E \end{aligned}$$

$$\begin{aligned} \min_{P,t} \quad & t \\ \text{s.t.} \quad & -tI \preceq P - \frac{11^T}{1^T 1} \preceq tI \\ & P = P^T \\ & P \geq 0 \\ & 1^T P = 1^T \\ & P_{ij} = 0 \ (i, j) \notin E \end{aligned}$$

Duality:

1. The Lagrange dual function

Consider the following problem:

$$p^* = \begin{cases} \min_x f_0(x) \\ \text{st } f_j(x) \leq 0, j=1 \dots m \\ h_j(x) = 0, j=1 \dots p \end{cases}$$

Define the Lagrangian:

$$L(x; \lambda, \mu) = f_0(x) + \sum_{j=1}^m \lambda_j f_j(x) + \sum_{j=1}^p \mu_j h_j(x)$$

↑
m priks
↓
p priks

priks priks ke zjed

- Мекагиен Лагранжс: создани оғын моза чабдым ресамын загауыт ашылады.

And the dual function:

$$g(\lambda, \mu) = \inf_x L(x; \lambda, \mu)$$

This may be hard to solve (in closed form or in non-convex) and where the art comes in by adding more constraints.

MCNDR, O'Gallagher

Weak duality : Goren

$g(\lambda, \mu) \leq p^*$ for any $\lambda \geq 0$ and μ .

Мы же сего хомини подумали.

Так мы и говорим о том что
мы будем оптимальными или нетные.

Всегда спрашиваем на
экзамене!

הוכחה:

$$p^* = f_0(x^*) \geq f_0(x^*) + \sum \lambda_i f_i(x^*) + \sum \mu_i h_i(x^*) =$$

↓ ↓ ↓
 גורן גורן גורן
 ≥ 0 ≤ 0 ≤ 0
 ↓ ↓ ↓
 x^* \in \mathbb{R}^n x^* \in \mathbb{R}^m x^* \in \mathbb{R}^n

≤ 0

(S.t $f_0(x^*) \leq f_0(x)$ ו $f_i(x^*) \leq f_i(x)$ ו $h_i(x^*) \leq h_i(x)$).

(Еще напомним что все забываюм, что $\lambda_i \geq 0$, $\mu_i \geq 0$, $x^* \in \mathbb{R}^n$, $x \in \mathbb{R}^m$).

$$= L(x^*, \lambda, \mu) \geq \inf_x L(x, \lambda, \mu) = g(\lambda, \mu)$$

Notations: We say that λ and μ are dual feasible if $\lambda \geq 0$
and $g(\lambda, \mu) > -\infty$.

The maximal lower bound

$$g(\lambda^*, \mu^*) = d^* = \max_{\mu, \lambda \geq 0} g(\lambda, \mu)$$

is called the dual program (and the
original is primal).



הוכיחו שהפונקציה $g(\lambda, \mu)$ היא מינימלית

$$g(\lambda, \mu) = -\infty : \text{אם } L \text{ זרqa} \quad ①$$

הוכיחו שהיא מינימלית $\Rightarrow g(\lambda, \mu) = \inf_x L(x; \lambda, \mu) =$ $\quad ②$

$$= \inf_x f_0(x) + \sum \lambda_j f_j(x) + \sum \mu_j h_j(x)$$

In addition we know that min concave
is concave, thus the written above is
always concave

He said: "L has 2 types of parameters
primal and dual.

- For every x , $L(x; \lambda, \mu)$ is concave
in $[\lambda, \mu]$.
- That's why \min_x is also
concave in $[\lambda, \mu]$.

Как перевести проблему и найти дуальную?

① Дана задача: Linear programming:

$$\begin{aligned} & \min_x C^T X \\ & \text{st } A X = b \\ & \quad X \geq 0 \end{aligned}$$



② Мы должны найти правильные λ и μ .

It's determined that we need them where the equality holds.

At that time as λ there will be non-negative 0.

This means that μ must hold $Ax = b$.

And λ must not hold. Therefore we have
 $-x \leq 0$.

We get: $L(x; \lambda, \mu) =$

$$= f_0(x) + \sum_{i=1}^m f_i \lambda_i + \sum_i h_i \mu_i =$$

$$= C^T x - \lambda^T x + \mu^T (Ax - b) =$$

$$= C^T x + \sum_i \lambda_i (-x_i) + \sum_i \mu_i (a_i^T x - b_i)$$

$$\bullet g(\lambda, \mu) = \inf L(x; \lambda, \mu) =$$

$$\text{вынесли } x \quad \leftarrow \quad = \inf_x \underbrace{[C + A^T \mu - \lambda]^T x}_{\lambda} - \mu^T b.$$

Proof: $\min_x \lambda x = \begin{cases} 0 & \lambda = 0 \\ -\infty & \lambda \neq 0. \end{cases}$
resultant, not x !

Good job!
Your first proof
in dual task!

$$\bullet g(\lambda, \mu) = \begin{cases} -\mu^T b & C + A^T \mu - \lambda = 0 \\ -\infty & \text{else} \end{cases}$$



③ В конце, мы получаем дуальную задачу которая выглядит таким образом:

$$\begin{cases} \max_{\mu, \lambda \geq 0} -\mu^T b \\ \text{s.t. } c + A^T \mu - \lambda = 0 \end{cases}$$

Strong Duality : Ген

If the problem is convex and Slater's condition (constraint qualification) holds, i.e there exists a strictly feasible point, then strong duality holds and $d^* = p^*$

Доказ.

We will prove $p^* \leq g(\lambda^*)$ because last lesson we saw weak duality ($p^* \geq g(\lambda^*)$) thus we will prove the equation.

$$① \quad g(\lambda^*) \geq p^*$$

$$② \quad \inf_x f_0(x) + \sum \lambda_i^* f_i(x) \geq p^*$$

③ goal:

$$f_0(x) + \sum \lambda_i^* f_i(x) \geq p^* \quad \forall x$$

if \inf is bigger than p^* , so other answers definitely.



- ④ For this purpose, we define two convex sets

$$A = \{ (u, t) / \exists x \ f_i(x) \leq u_i, f_0(x) \leq t \}$$

$m \times 1$ sign

$$B = \{ (0, t) / t < p^* \}$$

- ⑤ The set A captures all the solutions for the optimization plus the points which are worse than them, in fact we have.

$$p^* = \min_t t \text{ s.t. } (0, t) \in A$$

- ⑥ A and B don't intersect, and
ב-2-1 $(\tilde{x}, u) \neq 0$ סינען גאנן בס

$$(u, t) \in A \rightarrow \tilde{x}^\top u + \mu t \geq 2$$

$$(u, t) \in B \rightarrow \tilde{x}^\top u + \mu t \leq 2$$

- ⑦ If $(u, t) \in A$, then we can add arbitrary positive numbers to them and still be in A. Together with the first property this means $\tilde{x} \geq 0$ and $\mu \geq 0$ (otherwise $\tilde{x}^\top u + \mu t$ is unbounded from below).

From the second we have: $\mu t \leq 2$ & $t < p^*$
Or more simply: $\mu p^* \leq 2$.

Together: $\mu f_0(x) + \sum_i \tilde{x}_i f_i(x) \geq 2 \geq \mu p^* \quad \forall x$



$$\tilde{\lambda}_i = \frac{\tilde{\lambda}_i}{\mu} \quad : \text{if } \mu > 0 \text{ else } 0$$

$$f_0(x) + \sum \tilde{\lambda}_i f_i(x) \geq p^* \quad \forall x$$

$$f_i(\tilde{x}) < 0 \Leftarrow 0 < \mu \quad : \text{if } \mu > 0 \text{ else } 0$$

$$0 + \sum \tilde{\lambda}_i f_i(\tilde{x}) \geq 0 \quad : \text{if } \mu > 0 \text{ else } 0$$

$$\tilde{\lambda}_i = 0$$

■

Saddle point Interpretation:

$$p^* = \min_x \max_{\lambda \geq 0, \mu} L(x; \lambda, \mu)$$

$$d^* = \max_{\lambda \geq 0, \mu} \min_x L(x; \lambda, \mu)$$

- The first inner maximization is exactly f_0 with the domain defined as the feasible set.

$$\max_{x \geq 0, \mu} L(x; \lambda, \mu) = \begin{cases} 0 & x \text{ is feasible} \\ \infty & \text{otherwise} \end{cases}$$

The second inner minimization is exactly the definition of the dual problem

In general: $\max \min \leq \min \max$
 And that's the weak duality. Strong duality is the other way around and its solution is a saddle point:

$$L(x^*; \lambda, \mu) \leq L(x^*, \lambda^*, \mu^*) \leq L(x; \lambda^*, \mu^*)$$

"Saddle point záložnému má max min $\forall x \geq 0, \mu$
 u mákáce min max záložnému $\forall \lambda \geq 0, \mu$.
 mo - záleží".


הוכחה:

הו דענו שקיימים $C \cap D = \emptyset$

לפיכך $a \neq b$ ו- $x^T a = 0$

$$x^T a \leq b \quad \forall x \in C$$

$$x^T a \geq b \quad \forall x \in D$$



$$f(x) = x^T a - b$$

ולפיכך


הוכחה

- ① We only prove a special case where there exist two points $c \in C$ and $d \in D$ that are closest to each other in terms of Euclidean norm i.e.:

$$\|c-d\| = \inf_{\substack{c \in C \\ d \in D}} \|x-y\|$$

- ② In this case we define

$$a = d - c, \quad b = \frac{\|d\|^2 - \|c\|^2}{2}$$



And show that these define a separating hyperplane.

Specifically, let us show that $a^T x - b \geq 0$ on D



③ Our hyperplane is:

$$f(x) = a^\top x - b = (d-c)^\top x - \frac{\|d\|^2 - \|c\|^2}{2} = \\ = (d-c)^\top (x-d) + \frac{1}{2} \|d - c\|^2$$

④

$f(u) < 0$ מינימום קומבינטורי

$(0-\delta \text{ מילוי}) \cdot (x^\top a - b \geq 0)$ (בזק נא שיכל לנקוט)

: מינימום

$$(d-c)^\top (u-d) < 0$$

$t(u-d)$ מינימום של f ביחס ל- d ו- c (בזק נא שיכל לנקוט)

מינימום של f ביחס ל- d ו- c (בזק נא שיכל לנקוט)

ברכיבת ה- c ו- d

לכזה שיכל פג' פג' פג'

$$\frac{d}{dt} \left\| d + t(u-d) - c \right\|^2 \Big|_{t=0} =$$

$$= 2(d + t(u-d) - c)^\top (u-d) \underset{t=0}{\uparrow} = 2(d-c)^\top (u-d) = 0.$$



Farkas Lemma:

This is a theory of alternatives - the logic behind duality.

Basically gives us certificates for impossibility results.

Much stronger than showing possibility which is just by showing an example.

Similarly, to the fact that lower bounds to minimization problems are stronger than upper bounds.

Theorem:

Consider the two sets of inequalities

$$\text{I) } Ax \leq 0, c^T x < 0$$

$$\text{II) } A^T y + c = 0, y \geq 0.$$

Then, only one of them holds, i.e. each system is feasible if and only if the other is not.

Proof:

$$(P) \min c^T x \text{ s.t. } Ax \leq 0$$

$$(D) \max 0 \text{ s.t. } A^T y + c = 0, y \geq 0.$$

(P) is homogenous, therefore

$p^* = -\infty$ if (I) is feasible.

$p^* = 0$ if it isn't feasible.

(D) is also either $d^* = 0$ if (II) is feasible

OR $d^* = -\infty$ if it isn't feasible.

Due to $p^* = d^*$, feasible (I) means infeasible (II) and vice versa.

→ ГлГенеръ, с этой страницы, мы будем рассматривать множество примеров. Некоторые из них будут с лекций, а некоторые из глз. Всё же каждой будем отмечено откуда она.

E-optimal experiment design : Ex 3

Derive the dual program of :

$$\begin{cases} \min_x & \text{eigmax} \left[\left(\sum_{i=1}^p x_i a_i a_i^\top \right)^{-1} \right] \\ \text{s.t.} & x_i \geq 0 \quad \forall i \\ & \sum_{i=1}^p x_i = 1. \end{cases}$$

Solution:

$$① \text{ We use: } \text{eigmax}(A^{-1}) = \frac{1}{\text{eigmin}(A)}$$

② Equivalent to:

$$\begin{array}{ll} \min_{x, t \geq 0} & \frac{1}{t} \\ \text{(DPL) s.t.} & \sum_{i=1}^p x_i a_i a_i^\top \geq t I \\ & x_i \geq 0 \quad \forall i \\ & \sum_{i=1}^p x_i = 1. \end{array}$$



③ The lagrangian is:

$$L = \frac{1}{t} - \text{Tr}\{Z(\sum x_i a_i a_i^\top - tI)\} - \sum \lambda_i x_i + \mu \sum x_i - \mu$$

④ Minimizing over $t \geq 0$ yields:

$$\min_{t \geq 0} \frac{1}{t} + t \text{Tr}\{Z\} = \begin{cases} 2\sqrt{\text{Tr}\{Z\}} & Z \geq 0 \\ -\infty & \text{else} \end{cases}$$

⑤ Minimizing over X yields $-\infty$ unless:

$$-a_i^\top Z a_i - \lambda_i + \mu = 0$$

Noting that $\lambda_i \geq 0$ we get:

$$\begin{cases} \max_{Z, \mu} 2\sqrt{\text{Tr}\{Z\}} - \mu \\ \text{s.t. } a_i^\top Z a_i \leq \mu \quad \forall i \\ Z \geq 0 \end{cases}$$

⑥ The problem can be further simplified by defining

$$W = \frac{1}{\mu} Z \text{ where } \mu \geq 0 \text{ due to the constraints.}$$

Solving for μ yields a simple SDP

$$\begin{cases} \max_w \text{Tr}\{w\} \\ \text{s.t. } a_i^\top w a_i \leq 1 \quad \forall i \\ w \geq 0. \end{cases}$$

Boolean Linear Programming: Ex 3

$$\begin{array}{ll} \min & c^T x \\ \text{s.t.} & Ax \leq b \\ & x_i \in \{0, 1\} \end{array}$$

→ Prove that the linear relaxation using $0 \leq x_i \leq 1$ and the dual relaxation using constraints $x_i(1-x_i) = 0$, are equivalent

① Linear Relaxation is:

$$\begin{array}{ll} \min & c^T x \\ \text{s.t.} & Ax \leq b \\ & 0 \leq x_i \leq 1. \end{array}$$

② The lagrangian is:

$$L = c^T x + y^T (Ax - b) + u^T (x - 1) - v^T x$$

$$L = c^T x + y^T A x - y^T b + u^T x - u^T - v^T x$$

③ $g(\lambda, \mu) = \inf L(x; \lambda, \mu) =$

$$= \inf_x (c^T + y^T A - v^T + u^T) x - y^T b - u^T 1$$

④ and the dual:

$$\begin{cases} \max_{y \geq 0, v \geq 0, u \geq 0} & -y^T b - u^T 1 \\ \text{s.t.} & c + A^T y + u \geq 0 \end{cases}$$

⑤ or just:

$$\begin{cases} \max_{y \geq 0, u \geq 0} & -y^T b - u^T 1 \\ \text{s.t.} & c + A^T y + u \geq 0 \end{cases}$$



⑥ On the other hand, the dual relaxation is:

$$\begin{array}{ll} \min & C^T X \\ \text{s.t.} & X \leq b \\ & X_i - X_i^2 = 0 \end{array}$$

⑦ The Lagrangian is:

$$L = C^T X + Y^T A X - Y^T b - \sum_i \lambda_i X_i + \sum_i \lambda_i X_i^2$$

⑧

minimizing over X gives the dual function

$$g = \begin{cases} -Y^T b - \frac{1}{4} \sum_i \frac{(c_i + a_i^T y - \lambda_i)^2}{\lambda_i} & \lambda \geq 0 \\ -\infty & \text{else} \end{cases}$$

⑨ We need to maximize this function with respect to the dual variables.

$$\sup_{\lambda \geq 0} -\frac{(q - \lambda_i)^2}{4\lambda_i} = \begin{cases} q & q \leq 0 \\ 0 & \text{else} \end{cases} = \min\{0, q\}$$

⑩ So the dual program is simplified to:

$$\begin{cases} \max_y & -Y^T b + \sum_i \min\{0, c_i + a_i^T y\} \\ \text{s.t.} & y \geq 0 \end{cases}$$

⑪ That can be written as

$$\begin{cases} \max_{y,u} & -Y^T b - U^T u \\ \text{s.t.} & y \geq 0 \\ & u \geq 0 \\ & C + A^T y + U \geq 0 \end{cases} \blacksquare$$

Projection on Simplex : Ex 3

Derive the dual of the following problem.

Use only one Lagrange multiplier, so that the dual will be a simple line search.

$$\begin{aligned} & \min_x \|y - x\|^2 \\ & \text{s.t. } x \geq 0 \\ & \quad 1^T x = 1. \end{aligned}$$

① Now the problematic (non-separable) constraints is $1^T x = 1$ so we put a Lagrange multiplier on it

$$\max_{\mu} \min_{x \geq 0} \|y - x\|^2 + \mu - \mu 1^T x$$

which can also be written as:

$$\max_{\mu} \mu + \sum_i f_i(y_i; \mu)$$

where

$$f_i(y_i; \mu) = \min_{x_i \geq 0} \|y_i - x_i\|^2 - \mu x_i$$

has a simple closed solution:

$$x_i = \begin{cases} y_i + \frac{\mu}{2} & \text{if } y_i + \frac{\mu}{2} \geq 0 \\ 0 & \text{else} \end{cases}$$

LP with box constraints: Notebook

$$\begin{cases} \min_x c^T x \\ \text{s.t. } Ax = b \\ -1 \leq x \leq 1 \end{cases}$$

$$\begin{cases} \min_x c^T x \\ \text{s.t. } Ax = b \Rightarrow Ax - b = 0 \\ x \leq 1 \Rightarrow x - 1 \leq 0 \\ x \geq -1 \Rightarrow -1 - x \leq 0 \end{cases}$$

$$L = c^T x + \lambda^T (Ax - b) + \mu^T (x - 1) + \nu^T (-1 - x).$$

- Однако это нам дает не очень красивую дуальную проблему, поэтому можно записать primalную задачу несколько иначе:

$$\begin{cases} \min_x c^T x \\ x : \{x : -1 \leq x \leq 1\} \\ \text{s.t. } Ax = b \end{cases}$$

$$L(x; \lambda) = c^T x + \lambda^T (Ax - b)$$

$$g(\lambda) = \min_{-1 \leq x \leq 1} c^T x + \lambda^T (Ax - b)$$

$$\text{JITprox: } -|a| = \min_{-1 \leq x \leq 1} ax$$

$$\min_{-1 \leq x \leq 1} -\lambda^T b + x^T (A^T \lambda + c)$$

$$g(\lambda) = -\lambda^T b - \|A^T \lambda + c\|_1$$

And so we get the dual problem:

$$\min c^T x \text{ s.t. } Ax = b, \|x\|_\infty = 1. \blacksquare$$

Minimum norm solution: Notebook

$$\begin{array}{ll} \min & x^T x \\ \text{s.t.} & Ax = b \end{array}$$

$$L(x; \lambda) = L = x^T x + \lambda^T (Ax - b)$$

$$g(\lambda) = \min_x x^T x + \lambda^T A x - \lambda^T b$$

$$g(\lambda) = \min_x x^T x + x^T A^T \lambda - b^T \lambda$$

$$\frac{\partial L(x; \lambda)}{\partial x} = 2x + A^T \lambda = 0$$

$$x = -\frac{1}{2} A^T \lambda$$

Plugging in this solution yields:

$$\begin{aligned} g(\lambda) &= L\left(-\frac{1}{2} A^T \lambda; \lambda\right) = \\ &= x^T x + \lambda^T (Ax - b) = -\frac{1}{4} \lambda^T A A^T \lambda - b^T \lambda \end{aligned}$$

And the dual problem:

$$\max_{\lambda} -\frac{1}{4} \lambda^T A A^T \lambda - b^T \lambda$$

$-|X|^{1/n}$ function : Ex 1

Prove that the function $-|X|^{1/n}$ is convex on the set of $n \times n$ positive definite matrices.

Proof

- ① We will prove that $\det^{1/n}(x)$ is concave on $\{x \in S^n : x > 0\}$ by restricting it on a line.
 - This means than negation of the function is convex.

- ② The line : $g(t) = f(z + tv)$
where $z > 0$ and $v \in S^n$.

We need to show that $g(t)$ is concave
in t for all $t \in \{t : z + tv > 0\}$

$$\begin{aligned} ③ \quad g(t) &= \det^{1/n}(z + tv) = \\ &= \det^{\frac{1}{n}}(z) \cdot \det^{\frac{1}{n}}(I + t z^{-\frac{1}{2}} v z^{-\frac{1}{2}}) = \\ &= \det^{\frac{1}{n}}(z) \cdot (\prod_{i=1}^n (1 + t \lambda_i))^{1/n} \end{aligned}$$

- ④ Affine transformations preserve concavity and the geometric mean is concave. \rightarrow this we need to prove:



⑤ Geometric mean $f(x) = (\prod_{i=1}^n x_i)^{\frac{1}{n}}$ is concave on \mathbb{R}_{++}^n .

The Hessian is:

$$\nabla^2 f(x) = -\frac{\prod_{i=1}^n x_i^{1/n}}{n^2} \cdot \left(\begin{bmatrix} n \cdot \frac{1}{x_1^2} & & \\ & \ddots & \\ & & n \cdot \frac{1}{x_n^2} \end{bmatrix} - \begin{bmatrix} \frac{1}{x_1} \\ \vdots \\ \frac{1}{x_n} \end{bmatrix} \begin{bmatrix} \frac{1}{x_1} & \cdots & \frac{1}{x_n} \end{bmatrix} \right)$$

To show concavity, we prove that the Hessian is negative semidefinite:

$$\begin{aligned} v^\top \nabla^2 f(x) v &= -\frac{\prod_{i=1}^n x_i^{1/n}}{n^2} \left(n \cdot \sum_i \frac{v_i^2}{x_i^2} - \left(\sum_i \frac{v_i}{x_i} \right)^2 \right) = \\ &= -\frac{\prod_{i=1}^n x_i^{1/n}}{n^2} \left((\sum_i a_i^2)(\sum_i b_i^2) - (\sum_i a_i b_i)^2 \right) \leq 0 \end{aligned}$$

Where we define $a_i = 1$ and $b_i = \frac{v_i}{x_i}$
and the inequality holds due to
Cauchy Schwartz.

Problem no.4 : Ex 1

Consider the set of points whose distance to a point 'a' does not exceed a fixed fraction ' θ ' of the distance to another point b, i.e :

$$\{ x \mid \|x-a\|_2 \leq \theta \|x-b\|_2 \}$$

for some 'a' and 'b'. Is it convex?

Approach

$$\|x-a\|_2 \leq \theta \|x-b\|_2 \quad |^2$$

$$\|x-a\|_2^2 \leq \theta^2 \|x-b\|_2^2$$

$$x^T x - a^T x - x^T a + a^T a - \theta^2 (x^T x - b^T x - x^T b + b^T b) \leq 0$$

$$x^T x - a^T x - x^T a - a^T a - \theta^2 x^T x + \theta^2 b^T x + \theta^2 x^T b + \theta^2 b^T b \leq 0$$

$$(1-\theta^2)x^T x + a^T a - x(a^T - \theta^2 b^T) - x^T(a - \theta^2 b) - \theta^2 b^T b \leq 0$$

$$\Rightarrow (1-\theta^2)x^T x + a^T a - x(a - \theta^2 b)^T - x(a - \theta^2 b)^T - \theta^2 b^T b \leq 0$$

$$(1-\theta^2)x^T x + a^T a - 2x(a - \theta^2 b)^T - \theta^2 b^T b \leq 0 \quad /: (1-\theta^2)$$

$$x^T x + \frac{a^T a}{1-\theta^2} - \frac{2x(a - \theta^2 b)^T}{1-\theta^2} - \frac{\theta^2 b^T b}{1-\theta^2} \leq 0$$

$$x^T x - \frac{2x(a - \theta^2 b)^T}{1-\theta^2} \leq \frac{\theta^2 b^T b}{1-\theta^2} - \frac{a^T a}{1-\theta^2} \quad /+ c^T c$$

$$\left\{ \begin{array}{l} x^T x - \frac{2x(a - \theta^2 b)^T}{1-\theta^2} + c^T c \leq \frac{\theta^2 b^T b - a^T a}{1-\theta^2} + c^T c \\ c = \frac{a - \theta^2 b}{1-\theta^2} \end{array} \right.$$

$$\rightarrow \|x-c\|_2^2 \leq \frac{\theta^2 b^T b - a^T a}{1-\theta^2} + c^T c \quad |\sqrt{ }$$

$$\left\{ \begin{array}{l} \|x-c\|_2 \leq R \quad \rightarrow \text{this is ball, and it's convex. } \blacksquare \\ R = \sqrt{\frac{\theta^2 b^T b - a^T a}{1-\theta^2} + c^T c} \end{array} \right.$$